

# TRABAJO FIN DE GRADO

## GRADO EN INTELIGENCIA Y ANALÍTICA DE NEGOCIOS

### ÁRBOLES DE CLASIFICACIÓN PARA LA TOMA DE DECISIONES SOBRE ACCIONES

ALUMNO/A:	Juan Luis German Saura
TUTOR/A:	Francisco José Goerlich Gisbert
DEPARTAMENTO DEL TUTOR:	Análisis económico
CURSO ACADÉMICO:	2024-2025
FECHA DE DEPÓSITO:	28-05-2025



## **Resumen**

El presente trabajo evalúa la capacidad predictiva de modelos de clasificación basados en árboles de decisión (*rpart*) y bosques aleatorios (*randomForest*) para seleccionar acciones del IBEX 35 en función de perfiles de riesgo inversor. A partir de variables financieras transformadas en datos transversales, se construyen reglas de inclusión/exclusión de activos. Los modelos identificados como más idóneos consiguen métricas de rendimiento satisfactorias, siendo la calificación crediticia, la ratio Sharpe y la rentabilidad acumulada los principales determinantes en las decisiones de inversión dependiendo de la clase.

**Palabras clave:** Árboles de decisión, IBEX 35, clasificación de acciones, perfil de riesgo, inversión

## **Tabla de contenido**

<b>1. INTRODUCCIÓN.....</b>	<b>6</b>
<b>2. MARCO TEÓRICO.....</b>	<b>8</b>
2.1 Árboles de decisión.....	8
2.2 Variables clave y perfiles de riesgo .....	10
<b>3. DATOS Y FUENTES .....</b>	<b>11</b>
3.1 Descripción del IBEX 35 y selección de empresas.....	11
3.2. Precios de cierre históricos .....	12
<b>4. METODOLOGÍA .....</b>	<b>14</b>
4.1 Variables financieras.....	14
4.1.1 Variables de riesgo.....	14
4.1.2 Variables de rentabilidad .....	16
4.1.3 Variable de valoración.....	17
4.1.4 Variables de rentabilidad ajustada al riesgo .....	19
4.1.5 Integración y justificación de selección.....	20
4.2. Software y uso de librerías.....	21
4.3 Tratamiento de los datos.....	22
4.3.1 Procesado de datos .....	22
4.3.2 Transformación datos transversales.....	23
4.3.3 Análisis exploratorio .....	24
4.3.4 Introducción variable binaria.....	29
4.3.4.1 Umbrales variables volatilidad .....	29
4.3.4.2 Umbral variable rentabilidad .....	30
4.3.4.3 Umbral variable de valoración .....	30
4.3.4.4 Umbrales variables de rentabilidad ajustada al riesgo .....	31
4.4 Modelos y técnicas utilizadas.....	31
4.4.1 Estrategia de optimización de los hiperparámetros .....	32
4.5 Conjunto de entrenamiento y métricas de evaluación .....	33
4.6 Limitaciones del estudio .....	34

<b>5. RESULTADOS.....</b>	<b>35</b>
5.1 Entrenamiento de los modelos.....	35
5.1.1 Árboles genéricos.....	35
5.1.2 Optimización de hiperparámetros.....	38
5.2 Aplicación en el conjunto de prueba.....	40
5.2.1 Evaluación modelos para el perfil conservador .....	40
5.2.2 Evaluación modelos para el perfil tolerante .....	41
5.2.3 Evaluación modelos para el perfil neutral .....	42
5.4 Integración e interpretación general del test set .....	43
5.5 Limitaciones de los resultados .....	44
<b>6. CONCLUSIONES.....</b>	<b>45</b>

## Índice de ilustraciones

Ilustración 1: Ejemplo árbol de decisión.....	9
Ilustración 2: Fórmula cálculo rentabilidad acumulada.....	17
Ilustración 3: Mapa de calor de correlaciones .....	25
Ilustración 4: Tabla FIV comparativa.....	27
Ilustración 5: Interpretación valores FIV.....	27
Ilustración 6: Árbol de decisión conservador genérico <i>rpart</i> .....	36
Ilustración 7: Árbol de decisión tolerante genérico <i>rpart</i> .....	36
Ilustración 8: Árbol de decisión neutral genérico <i>rpart</i> .....	37
Ilustración 9: Tabla resumen métricas de errores de RF y <i>rpart</i> en el train set.....	37
Ilustración 10: Árbol de decisión conservador optimizado <i>rpart</i> .....	38
Ilustración 11: Árbol de decisión tolerante optimizado <i>rpart</i> .....	39
Ilustración 12 Árbol de decisión neutral optimizado <i>rpart</i> .....	39
Ilustración 13: matriz de confusión RF conservador.....	41
Ilustración 14: matriz de confusión <i>rpart</i> genérico tolerante .....	42
Ilustración 15: matriz de confusión <i>rpart</i> optimizado neutral.....	43
Ilustración 16: Comparación significatividad para modelos escogidos por perfil.....	44

## **1. INTRODUCCIÓN**

En un mundo en el que cada vez las decisiones financieras se vuelven más complejas debido al alto grado de dificultad que atañe el entendimiento de los productos financieros, propios de aquellos países más desarrollados, hace que esta tarea cobre constantemente un aumento de importancia para el individuo, debido a que mayores grados de libertad suponen una mayor autonomía en la elección de las decisiones propias, pero con la contrapartida de una mayor responsabilidad personal sobre la opciones que acaban siendo escogidas<sup>1</sup>.

Sumado al aumento del desarrollo tecnológico a escala global, la accesibilidad a la adquisición de activos financieros ha ido también en aumento, por lo que existe una mayor proporción de personas que han adquirido posesión sobre activos a través de este método<sup>2</sup>, impulsando el nacimiento de nuevos inversores minoristas está en auge. Estas tendencias se han ido aconteciendo igualmente en elementos altamente relacionados entre sí como lo son los fondos indexados, ETFs y acciones<sup>3</sup>.

A causa de lo anterior, la toma de decisiones en la adquisición de activos financieros se ha vuelto cada vez más compleja, debido a la expansión de los mercados. Discernir en entornos en los que prima la volatilidad y la incertidumbre, en los que el riesgo siempre está presente y añadiendo que existe una altísima cantidad de información para analizar<sup>4</sup>, todo ello crea la necesidad de encontrar herramientas que ofrezcan soluciones relativamente simples a la problemática planteada.

De esta forma, la razón principal por la cual se ha realizado el trabajo, es dar respuesta a este tipo de decisiones tan vitales para el contexto financiero del creciente número de inversores particulares que cada vez se interesan más por mantener igual o aumentar su bienestar financiero<sup>5</sup>, que influye directamente en las perspectivas vitales del sujeto. Consecuentemente, se propone como hipótesis principal determinar si los árboles de decisión son una herramienta efectiva para clasificar acciones del IBEX 35 en función de variables clave y diferentes perfiles de riesgo.

Por consiguiente, la aplicación de modelos de *machine learning* aplicados a los problemas de clasificación, como son los árboles de decisión/clasificación<sup>6</sup>, son una de las varias herramientas existentes que pueden ser aplicadas para la resolución de estas situaciones desarrolladas bajo panoramas sofisticados.

Gracias a estos algoritmos, se dispone de una identificación sencilla sobre las reglas de clasificación que se utilizaron para la inclusión o no sobre los elementos analizados en una cartera de activos. Las reglas se crearán a partir de las variables consideradas que tratan circunstancias claves en la exploración de los activos, como son la volatilidad, la rentabilidad histórica, la calificación crediticia, etc.

Debido a esto, la aplicación de los patrones encontrados puede ayudar a comprobar que factores son determinantes en la toma de decisiones, simplificando ampliamente el proceso de análisis, brindando soluciones abreviadas para los inversores particulares sobre las variables más significativas, dependiendo del nivel de riesgo que toleraría cada inversionista.

En cuanto a la revisión de la literatura, sobre investigación de temas similares, los autores Yehan Wang (2024)<sup>7</sup> utilizaron árboles de decisión con variables parecidas, pero el objetivo principal era la predicción del precio de la acción junto con maximizar la rentabilidad de la cartera, sin tener en cuenta los perfiles de riesgo. Por otra parte, Klokholm y Thomsen (2025)<sup>8</sup>, vuelve a utilizar factores similares para la predicción, pero con el fin de optimizar la composición de la cartera de activos.

Para llevar a cabo este cometido, se han recopilado, procesado y manipulado los datos mensuales entre los años 2016-2024 de las empresas con más ponderación pertenecientes al índice del IBEX 35. De esta manera, quedaría evaluar la calidad de las predicciones realizadas por los modelos según la disposición al riesgo de cada persona, que se organizaría en tres niveles según su aversión al mismo, los cuales serían: el perfil tolerante, el conservador y el neutro.

Con ello, se establecería como objetivo principal del trabajo el reconocimiento de las variables clave para la inclusión de activos en un portfolio para mejorar la toma de decisiones financieras sobre esta clase de activos.

Otros fines secundarios que se pretende tratar de alcanzar serían los siguientes: tratar de agilizar el análisis de los grandes volúmenes de datos para sintetizar y examinar los rendimientos de los modelos entrenados según el nivel de riesgo para cada inversor particular.

De este modo, para la consecución de todo lo que se ha ido exponiendo en la introducción, el resto del trabajo se estructurará en un cuerpo central, mediante la determinación de un marco teórico donde se situarán las bases teóricas y las hipótesis

a investigar, la metodología en la que se explicarán los instrumentos utilizados, los resultados con su pertinente análisis junto con su explicación y con una comparativa con el marco teórico previo, finalizando con las conclusiones presentadas como síntesis del trabajo.

## **2. MARCO TEÓRICO**

### **2.1 Árboles de decisión**

Se definen los árboles de decisión como algoritmos de *machine learning* que permiten la construcción de modelos predictivos capaces de ser aplicados a problemas de índole clasificatoria o relacionados con la regresión, lo que resalta el gran abanico de posibilidades a desarrollar y la aplicabilidad que pueden llegar a tener. Su valor radica en su capacidad para analizar grandes volúmenes de datos (*Big Data*), identificar patrones y tomar decisiones basadas en la información obtenida<sup>9</sup>.


Sobre la aplicación en el campo de la regresión, el fin central es la predicción de una variable continua a partir del resto de variables independientes encontradas en el conjunto de datos utilizado. Como ejemplo del rendimiento que es posible obtener, los autores Máximo Camacho, Salvador Ramallo, Manuel Ruiz Marín (2021)<sup>10</sup>, determinaron en su estudio del precio de la vivienda, la habilidad que atesoran este tipo de modelos.

En cuanto a los modelos de clasificación, estos utilizan variables binarias para categorizar los datos. Para este caso específico, esta variable binaria es manipulada según umbrales definidos sobre cada factor para cada perfil inversionista, por lo que esta variable categórica puede cambiar en su valoración “incluido” o “no incluido” para cada empresa según cada escenario<sup>11</sup>.

Los árboles de clasificación constan en su formación de nodos y ramas y siguen una estructura jerárquica propia de un árbol como el mismo nombre indica. El árbol tiene en la parte superior el nodo raíz, que representa la condición a evaluar sobre la que se centra el árbol. En el siguiente nivel estarían los nodos internos, que representan las pruebas lógicas (reglas) intermedias, que se dividen en función de las distintas características que considera el árbol. En el nivel más bajo están los nodos hoja, que son los puntos terminales del árbol donde se llega a una decisión concreta y no tienen más ramas salientes. Todos estos nodos se encuentran por unidos por las ramas, que



son las encargadas de conectar los nodos según los resultados de las pruebas lógicas presentadas en los puntos intermedios de los nodos internos<sup>12</sup>.



**Ilustración 1: Ejemplo árbol de decisión**

Estas herramientas, además de las comentadas en la introducción, utilizan árboles de decisión mediante factores como la calificación crediticia. Con estas bases como antecedentes, se encuentra suficiente evidencia para ejemplificar como sirven para simplificar la toma de decisiones en la selección de activos dentro del ámbito financiero.

Por ello, como ventajas de los árboles de decisión es fácilmente visible la gran interpretabilidad que proporcionan, ya que exponen de manera clara los patrones encontrados de forma totalmente visual, por lo que las características de justificabilidad y transparencia están más que presentes en los árboles de clasificación. Asimismo, permite manejar variables tanto categóricas como numéricas, lo que permite una mayor flexibilidad a la hora de aplicar este tipo de modelos a conjuntos de datos más diversos, causando que se puedan adaptar a distintos contextos.

Sin embargo, el punto negativo que se debe tener en cuenta sobre los árboles de clasificación es la gran propensión que tienen en caer en errores de sobreajuste, ajustándose en exceso a los datos de entrenamiento, ello llevando a la creación de modelos poco robustos que sufren de variaciones altamente significativas en su rendimiento y actuación con pequeñas modificaciones en el conjunto de datos. Para ello existen métodos de poda o bien *random forest* para mitigar esta debilidad. Relacionado con ello, los árboles de decisión pueden sufrir en la precisión de las predicciones que generarían si existiera un desbalance de clases.

## **2.2 Variables clave y perfiles de riesgo**

La tarea de escoger entre una vasta gama de opciones entre los activos financieros adquiribles, como son las acciones, depende de las deducciones que se hagan sobre las variables que miden diferentes aspectos. La importancia que tienen se debe a la oportunidad que estas representan para los inversores en cuanto a la toma de decisiones informadas, que a través del análisis de las métricas, permite el mayor ajuste posible a las necesidades de cada inversionista en la distinción de cada instrumento financiero<sup>13</sup>.

De esta forma, los elementos cruciales que han sido capaces de ser recopilados desde fuentes públicas serían aquellos que examinan la valoración de la acción, el riesgo, la rentabilidad pura y la rentabilidad ajustada al riesgo. Mediante estas categorías, es cuantiosamente más sencillo entender que dimensiones son las más significativas para la tarea de la clasificación que realiza el árbol de decisión.

Por medio de esta agrupación, se puede establecer que, a rasgos generales, para los inversores que caigan en los distintos grupos diferenciados según el factor de la inestabilidad, los inversores con alta aversión al riesgo (conservadores), se inclinarán hacia posturas donde la volatilidad global de la acción sea baja y la rentabilidad de la misma sea mínimamente positiva. Para aquellos con una condición de baja aversión al riesgo (tolerantes), estos pueden llegar a permitirse correr mayores riesgos para tratar de alcanzar las mayores rentabilidades posibles. En cuanto a los tipos intermedios en la aversión, estos buscarían un equilibrio entre ambas dimensiones estudiadas.

De igual modo, se debe resaltar que estas variables presentan algunas limitaciones. Por un lado, la imposición de solo poder explorar a partir del año 2016 reduce bastante la amplitud de la capacidad de recogida de datos, ya que hay empresas que tienen información disponible desde el año 2000 que no se puede aprovechar al tener una obligación en mantener el mismo horizonte temporal para todas las compañías consideradas.

Además, los cambios en la totalidad del mercado pueden afectar a selectas variables al depender en sus cálculos directamente de este, por lo que circunstancias no tomadas en cuenta en el análisis pueden seguir teniendo un impacto relevante, por lo que no existe un escenario totalmente independiente ni manipulable para los fines del trabajo, ya sea empresas pertenecientes al índice del IBEX 35 u otros mercados internacionales.

### **3. DATOS Y FUENTES**

#### **3.1 Descripción del IBEX 35 y selección de empresas**

Un índice bursátil es un indicador histórico que recoge todas las acciones para cada empresa que compone dicho índice. De esta manera, un índice bursátil sirve a un propósito de simplificación de información, ofreciendo la evolución de los valores de las acciones de todas las acciones que tiene en cuenta<sup>14</sup>.

Por esto, el índice contemplado para este proyecto ha sido el más importante dentro del mercado financiero español, que es el IBEX 35. La transcendencia de este índice surge porque se encarga de registrar a las empresas con mayor volumen de negociación dentro del mercado español, que a su vez reúne las bolsas de Madrid, Barcelona, Bilbao y Valencia. Se debe mencionar, que la composición de este índice es variable, ya que pueden existir movimientos de entrada y de salidas para aquellas empresas que aumentan o disminuyen su liquidez, por lo que la constitución del IBEX 35 está en constante revisión por un Comité Asesor Técnico (CAT)<sup>15</sup>.

Así pues, para llevar a cabo el cometido las intenciones diseñadas, se ha optado por realizar una criba sobre el índice para reunir los datos sobre las 20 empresas más simbólicas de todos los sectores presentes, priorizando aquellas que más peso y ponderación tienen según la capitalización bursátil dentro del índice (anexo 1)<sup>16</sup>. Esto se ha realizado con la intención de encontrar un equilibrio entre representatividad de la diversidad del índice y la simplicidad, es decir, los modelos generados buscan minimizar el sobreajuste al equilibrar la estabilidad del análisis con la naturaleza dinámica del mercado financiero español<sup>17</sup>.

Por tanto, se ha tratado evitar el sesgo de muestreo con este enfoque de abundante variedad sectorial de las compañías tomadas en cuenta, para así conseguir una generalización robusta sacrificando cierta especificidad por falta de cobertura total del mercado financiero, es decir, la problemática de la compensación entre el sesgo y varianza<sup>18</sup>.

Entrando en más detalles de las empresas por las que se ha optado en el análisis, el primero de todos los sectores considerados ha sido el financiero, en el que están bancos como: *Santander*, *Caixabank*, *BBVA*, *Sabadell* y *Bankinter*, encargados de ofrecer servicios financieros. Este tipo de actividad es uno de los pilares más

importantes del IBEX 35, al pertenecer un gran número de este tipo de compañías a este mismo sector y ser a su vez empresas internacionalizadas algunas de ellas.

El segundo sector a considerar es el energético, en el que han entrado: *Iberdrola*, *Endesa*, *Repsol*, *Redeial* y *Naturgy* encargadas de una serie de tareas como la distribución de la electricidad, el gas y el petróleo.

El tercer ámbito empresarial es el referente a la telecomunicación y la tecnología, en el que se encuentra a la reconocida *Telefónica* (presencia en Latinoamérica), junto con *Amadeus*, *Cellnex* y *Acciona*.

El antepenúltimo sector ha sido el relacionado con la industria y construcción, donde localizan *Ferrovial* y *ACS*, delegadas a ofrecer respuesta al mercado inmobiliario.

El penúltimo sector es el de consumo, donde se agrupan *Inditex*, *IAG* y *Aena*. Aunque las actividades de estos negocios difieran entre sí, todos tienen en común la venta al por menor.

Por último, el sector de la salud lo representa la empresa *Grifols*, centrándose en todo lo relacionado con la producción y venta del plasma a nivel internacional<sup>19</sup>.

Esta diversificación sectorial permite conseguir y seguir la aproximación establecida en párrafos anteriores, por lo que se trata de obtener la imagen más amplia del principal mercado financiero español sin tener que reunir la información de todas las empresas integrantes del índice bursátil.

### **3.2. Precios de cierre históricos**

Una vez ya establecidas las empresas sobre las que se va a realizar el trabajo de recolección de datos, la fuente más asequible por su naturaleza, al ser de libre acceso y gratis, ha sido la denominada como *Yahoo Finance*, una plataforma diseñada para proporcionar datos financieros, reportes financieros, noticias de prensa relacionadas con el ámbito y almacenar públicamente los registros históricos de compañías con presencia en bolsa.

Esta base de datos pública es de extrema utilidad porque permite la posibilidad de extraer la variable base a partir de la cual se crean el resto de las variables derivadas, que es el precio de cierre de la acción. Como ejemplo de esto, algunos de los indicadores considerados en la creación de los modelos, como las medidas de riesgo (volatilidad<sup>20</sup> y beta), de rentabilidad<sup>21</sup> (acumulada, mensual y relativa) y de rentabilidad

ajustada al riesgo (alfa de Jensen<sup>22</sup> y ratio de Sharpe<sup>23</sup>) se calculan directamente con el precio de cierre de la acción.

El precio de cierre es la muestra del último precio en el que se cerró la última transacción de un activo concreto durante el horizonte temporal escogido. De esta manera, el precio de cierre se convierte en un elemento central para cualquier persona interesada en el campo de la bolsa, ya que se transforma en la referencia base al reflejar el comportamiento y la valoración por parte de los inversores de un activo determinado. Gracias a esto, si se analiza el precio de cierre histórico de cualquier activo, es posible captar las tendencias generales sobre el comportamiento y valoración de dicho activo<sup>24</sup>.

Sumado a esto, *Yahoo Finance* ofrece más ventajas aparte de la posibilidad de obtener el precio de cierre a través de sus datos. Estos puntos positivos son la sencilla integración que ofrece con el lenguaje de programación que se utiliza para el tratamiento de los datos (R), mediante el paquete *quantmod*<sup>25</sup>, que facilita la automatización del análisis. Además, la plataforma ofrece una cobertura histórica lo suficientemente amplia como para llevar a cabo el análisis con una cantidad de información aceptable para la ejecución del proyecto.

Teniendo esto presente, la frecuencia temporal por la que se ha optado obtener de entre las disponibles (anual, semestral, trimestral, mensual y diaria) ha sido la mensual, fundamentalmente por el hecho de que se elimina la posibilidad de tener en los datos descargados valores faltantes, que dificulten las tareas posteriores. Añadido a esto, la frecuencia mensual permite poder evaluar tendencias más a largo plazo que si se escogiera, por ejemplo, una frecuencia diaria.

No obstante, la única limitación con respecto a los precios de cierre en bolsa, es que no todas las empresas coinciden en el mismo horizonte temporal, ya que la idea inicial fue examinar el período comprendido entre los años 2000-2024 y eventualmente se ha tenido que reducir este lapso significativamente hasta los años 2016-2024, a fin de garantizar la coherencia y calidad de los datos, que es donde todas las empresas coincidían sobre el registro de datos histórico y así poder realizar tareas de comparación entre las métricas generadas, mediante un conjunto de datos homogéneo y consistente.

Por estas razones, los datos que ofrece *Yahoo Finance* permiten analizar los datos de los precios de cierre históricos, pero su análisis detallado escapa al alcance de este estudio.) y las variables relacionadas, lo que concede la opción de tener la base de

datos necesaria para partir hacia el entrenamiento de los modelos de clasificación, evaluando la idoneidad de cada activo en función de sus características financieras.

## **4. METODOLOGÍA**

### **4.1 Variables financieras**

Del mismo modo con el que se ha profundizado sobre los precios de cierre históricos, es igual de esencial explicar el significado de todas las variables consideradas en la constitución de la base de datos utilizada, para llegar a acometer el objetivo del proyecto propuesto. Estas métricas permiten evaluar aspectos clave como el riesgo, la rentabilidad, la rentabilidad ajustada al riesgo y la valoración del activo.

#### **4.1.1 Variables de riesgo**

Comenzando por el riesgo, este factor se refiere a la incertidumbre que posee intrínsecamente un activo sobre el retorno que este es capaz de dar dependiendo de la evolución temporal que repercute sobre su valor. De esta manera, hay un riesgo diversificable que es posible de mitigar mediante la actividad del inversor y otro no diversificable que se sufre por circunstancias externas como la evolución de la economía nacional. Este trabajo en concreto se centra en paliar el riesgo de tipo diversificable mediante los indicadores que se han tenido en cuenta<sup>26</sup>.

Dentro de esta clase de métrica, se han manejado tres variables para observar el comportamiento del precio de cierre de las acciones sobre las empresas incluidas. De tal forma, está la volatilidad mensual, la cual trata de medir la variación de los precios de cierre de las acciones para el período estudiado, por lo que mide tanto la dispersión de precios como la incertidumbre del mercado. Los valores según las circunstancias del perfil de cada individuo pueden ser vistos como una oportunidad o una amenaza<sup>27</sup>.

Para poder calcular esto, se hace uso de la desviación típica para contar cuanta ha sido la dispersión media de la acción. Gracias a esta variable, se puede extraer la interpretación de que, a mayor volatilidad, mayores movimientos bruscos en su evaluación y por tanto mayores posibilidades de que se desvíe la acción del precio esperado

Siguiendo con el riesgo, también se ha contemplado el beta, que mide la variabilidad pero a diferencia de la volatilidad, la valoración se hace en comparación con un índice de referencia, que en este caso se aplica en base a la volatilidad del IBEX 35. Para realizar su cálculo, se divide la covarianza del rendimiento de la acción y del índice de referencia por la varianza del rendimiento del índice de referencia durante el período seleccionado. A través de los resultados de esta variable, a mayor beta, mayor es la volatilidad en comparación con el índice seleccionado y como consecuencia, mayor riesgo. De esta manera, si el beta supera el 1, esto indica que la acción es más volátil que el resto del mercado y de forma opuesta, si es menor de 1 la acción es más estable que el índice restante<sup>28</sup>.

Finalizando con este tipo de parámetro, la calificación crediticia es el último aspecto sopesado. El rating se encarga de representar la solvencia financiera de la empresa emisora de la acción. Por ello, se visualiza la capacidad de la empresa de hacer frente a la deuda emitida, por lo que a mejor calificación, menor será el riesgo de invertir en ella. En los casos contrarios, el coste de financiación de la empresa aumenta, lo que puede perjudicar a la valoración del valor de la acción en el índice bursátil<sup>29</sup>.

Las agencias privadas a partir de las cuales se han tomado sus datos como marca base han sido *Standard&Poor's* y *Fitch*, y estas suelen contemplar elementos como el historial de pagos y la actual relación de bienes y deudas del emisor para realizar sus *ratings*. Además, estas agencias proporcionan calificaciones tanto para el corto como el largo plazo y no existe un código homogéneo por el que se rigen estos organismos en sus valoraciones.

Por estas condiciones, se ha escogido los *ratings* a largo plazo ya que el largo plazo se centra en la capacidad de la empresa de forma estructural en un horizonte prolongado, hecho que va en sigue la línea del proyecto, que trata de buscar patrones generalizables a través de las reglas de decisión en modelos lo más estables posibles. Esto no sería posible con valoraciones a corto plazo que se centrarían más en variaciones temporales volátiles que irían en contra de la consistencia metodológica del trabajo y que añadirían ruido innecesario en los datos.

Asimismo, haber seleccionado como agencias a *Standard&Poor's* y *Fitch*, se debe a su sistema de puntuación intuitivo a largo plazo, fiables al ser reconocidos mundialmente y altamente similar (anexo 2) que permite fácilmente realizar comparaciones sin necesidad de hacer conversiones complejas.

#### **4.1.2 Variables de rentabilidad**

Una vez finalizado el apartado que tiene que ver con el riesgo, se pasa a examinar el punto de la rentabilidad. La rentabilidad es la medida financiera que permite cuantificar el rendimiento de un activo financiero, es decir, la relación existente entre el beneficio conseguido y el dinero invertido para crear ese lucro<sup>30</sup>.

Para el respectivo panorama de las acciones en bolsa, la rentabilidad es la suma de la revalorización y del rendimiento de la inversión. Por estas cuestiones, calcular la rentabilidad de la inversión es de suma importancia, ya que permite evaluar el desempeño del activo y porque permite determinar si se están consiguiendo los objetivos financieros por parte del inversionista y así poder ejecutar las decisiones más oportunas posibles. De este modo, se han calculado tres clases de rentabilidad desde diferentes perspectivas.

La rentabilidad mensual es la primera a explicar por ser la más simple de las tres. Básicamente, esta rentabilidad mide la propia variación porcentual del precio de cierre de la acción de la empresa correspondiente en el tiempo escogido. Como la frecuencia de los datos es mensual, consecuentemente, el análisis de los resultados de la acción será mensual. Sumado a la frecuencia, en el cálculo se han utilizado los logaritmos naturales para suavizar las fluctuaciones, lo que permite obtener tasas más estables y comparables entre otros activos, hecho que soluciona posibles problemas de distribución, ya que con los logaritmos se consigue una aproximación más simétrica en la distribución, que puede llegar a ayudar en construir reglas de clasificación más balanceadas<sup>31</sup>.

Por otra parte, la rentabilidad acumulada se refiere a las ganancias totales alcanzadas desde el inicio del intervalo establecido. Por eso, este tipo de rentabilidad es la responsable de visualizar el crecimiento total y global de la inversión a lo largo del tiempo<sup>32</sup>.

Para su cálculo, existen dos opciones de obtención, siendo la que supone que los inversores mantienen su inversión en la acción y reinvierten los beneficios obtenidos mes a mes y el caso contrario más cortoplacista y donde no existe reinversión en el activo. Sabiendo el contexto del proyecto, se ha optado por la primera opción, ya que es más representativa para el escenario que se plantea a largo plazo y que refleja el crecimiento real del activo mantenido en el tiempo. Para conseguir una visión crucial



para estrategias enfocadas al largo plazo y aplicable a contextos de comparación con otros activos financieros<sup>33</sup>, se realiza el siguiente cálculo:

$$\text{Rentabilidad Acumulada} = \left( \prod_{i=1}^n (1 + R_i) - 1 \right) \times 100\%$$

Ilustración 2: Fórmula cálculo rentabilidad acumulada (elaboración propia)

La última rentabilidad considerada ha sido la rentabilidad relativa frente al índice bursátil del IBEX 35. Esto hace que directamente se deduzca que lo que se intenta conseguir es una comparación directa entre el activo escogido y un *benchmark*. Así, la tarea de encontrar activos que se queden por detrás o superen al mercado en el que se encuentran se facilita al tener un cálculo inmediato que se ocupe de esto. La operación necesaria para obtener la rentabilidad relativa es una simple resta entre la rentabilidad mensual del activo y la rentabilidad mensual del índice de referencia<sup>34</sup>.

#### **4.1.3 Variable de valoración**

La valoración de activos tiene como objeto estimar el valor intrínseco de un activo, lo cual representaría la capacidad de identificar posibles discrepancias entre la estimación real de un activo entre el precio del mercado, lo cual se relaciona al conocido como tareas propias del análisis fundamental<sup>35</sup>.

Como consecuencia, el valor intrínseco está directamente influenciado por factores externos que alteran su precio, que van desde la macroeconomía hasta la perspectiva de los inversores y eventos geopolíticos.

De esta manera, esta actividad cobra especial aprecio por la posibilidad de encontrar aquellos activos que se hayan convertido en sobrevalorados o en infravalorados, lo que acaba siendo un proceso que permite optimizar las opciones de inversión y anticiparse a posibles convulsiones del mercado financiero.

La variable de variación incorporada al análisis ha sido el P/E ratio (relación precio-beneficio) que logra captar la comparación entre el precio de la acción entre las ganancias por acción de la compañía. Este indicador proporciona una medida de cuánto están dispuestos a pagar los inversores por unidad de beneficio, ya que la ratio indica cuántos años de ganancias necesitaría una empresa para igualar el precio actual de su acción, asumiendo que sus beneficios no cambian<sup>36</sup>.

Por consiguiente, la interpretación general que se puede sacar es evaluar el atractivo que posee el activo como inversión. Dependiendo de los valores obtenidos, a mayores niveles de P/E, los inversores esperan un crecimiento futuro significativo. En el caso contrario en el que el valor es menor, los inversionistas creen que habrá un crecimiento moderado o tienen una preocupación por la evolución del negocio. Así pues, cabe señalar que el P/E ratio puede resultar, por un lado, engañoso para empresas con expectativas de crecimiento muy altas o muy bajas, al no tener en cuenta el crecimiento futuro de los beneficios, y por otro, puede sufrir grandes distorsiones con beneficios/panoramas inestables.

Cabe destacar que esta variable, junto a la calificación crediticia no es posible que sea calculada a partir de los precios de cierre mensuales de las acciones consideradas, ya que la fórmula es la división entre el precio de la acción y el beneficio por acción. Por esta razón, se ha tenido que acudir a varias y diversas fuentes de información que ofrecían esta información en forma de registro histórico con una frecuencia anual<sup>37</sup>.

Entre las fuentes consultadas se encuentran: *Macrotrends* (Santander), *Invesgrama* (Iberdrola y BBVA), *FinanceCharts* (CaixaBank), *Expansión* (Iberdrola, BBVA, Aena, Cellnex, Banco Sabadell y Bankinter), *Marketscreener* (IAG, Redeia, Endesa y Naturgy), *Eulerpool* (Grifols), *Statista* (BBVA y ACS), *CompaniesMarketcap* (Aena, Cellnex, Repsol, Banco Sabadell, Redeia, Bankinter Naturgy), *Wisesheets* (Aena) y los informes corporativos de Amadeus (años 2011, 2013 y 2017).

Además, se han utilizado datos del beneficio por acción de algunas empresas, como ACS (*Statista*) y Endesa (a través de *Invesgrama* y *Marketscreener*), para calcular la ratio PER aplicando la fórmula correspondiente cuando no se disponía directamente de la ratio.

Seguido de esto, como los datos obtenidos estaban generados anualmente, se ha acudido al método de interpolación lineal para conseguir la transformación mensual. Esta técnica es comúnmente aplicada para casos concretos como el que se describe, ya que se estima los valores intermedios del P/E entre las fechas de las que se tienen datos. Esta estimación se realiza bajo la suposición de que el cambio del precio es constante durante el período (relación lineal como supuesto), por lo que puede ser algo ineficaz en captar la evolución real del indicador por si llega a tener comportamientos volátiles, aunque es una opción sencilla de aplicar, que lo convierte

en una opción conveniente. Como consecuencia, este método garantiza la comparabilidad con el resto de las variables que están en el formato mensual<sup>38</sup>.

#### **4.1.4 Variables de rentabilidad ajustada al riesgo**

Estos indicadores evalúan el valor de realizar según el riesgo que conlleva por el retorno conseguido. Fundamentalmente, como a mayor riesgo sufrido, mayor es la ganancia obtenida, estas variables tratan de conseguir un equilibrio óptimo entre los elementos de rendimiento potencial e incertidumbre de cada inversión. Por ello, estos factores buscan alcanzar retornos lo más interesantes sin correr riesgos excesivos, aunque en la práctica esto sea una situación óptima, acercarse lo máximo posible es un aspecto altamente positivo<sup>39</sup>.

Dentro de este parámetro, una de las variables es la ratio de Sharpe, es la rentabilidad que ofrece una inversión por cada unidad de riesgo asumida. De esta manera, con esta ratio se puede comparar carteras de activos con diferentes riesgos y estipular cuál ha sido la más exitosa. La ratio se calcula mediante la resta entre la rentabilidad del índice menos la tasa de interés libre de riesgo (normalmente los bonos de gobierno, que se consideran prácticamente seguros<sup>40</sup>) dividido por la desviación estándar<sup>41</sup>.

La explicación que se saca de esta métrica se basa en que, a mayor valor, mejor es la gestión del riesgo y es más deseable esa inversión (normalmente superiores a 1 son considerados gestiones positivas). Sin embargo, si fuera negativo esto significaría que su rendimiento es menor al de la rentabilidad sin riesgo.

La otra variable incluida es el alfa de Jensen que mide si la inversión supera al rendimiento esperado en relación con el riesgo que conlleva. Por lo tanto, la métrica calcula el valor que añade el gestor de la inversión por encima del rendimiento que se debería esperar según el modelo de mercado y el riesgo (beta<sup>42</sup>).

La comprensión que se saca del alfa de Jensen es que si este es positivo, la inversión ha tenido mejor comportamiento para el nivel de riesgo comprometido. Si fuera negativo, mostraría el caso contrario.

Por estos motivos, ambos parámetros evalúan la recompensación del retorno de la inversión contemplando la volatilidad total. Mientras que la ratio de Sharpe se centra en la comparativa entre diferentes activos o carteras, el alfa de Jensen se ocupa de ver la habilidad del gestor sobre el activo frente al índice de referencia.

Aun así, existen limitaciones con estos indicadores, ya que la ratio de Sharpe asume que los retornos siguen una distribución normal, (en este caso se aproximan por la utilización de logaritmos en explicaciones previas) por lo que puede ser impreciso con distribuciones asimétricas<sup>43</sup>. El alfa de Jensen asume que el mercado siempre es eficiente y cuantifica el riesgo basándose solamente en la beta, lo cual puede no darse en todos los activos examinados.

Pese a ello, tener variables presentes que estudien la relación riesgo-beneficio es interesante. Ambas ratios con valores altos pueden llegar a ser inversiones interesantes para perfiles más conservadores, en comparación con un perfil más tolerante a la incertidumbre que podría validar resultados más bajos.

#### **4.1.5 Integración y justificación de selección**

Este apartado surge por la necesidad de crear un apartado puente que aporte contexto y conexión entre toda la redacción del trabajo.

Para comenzar, las variables del riesgo cuantifican la incertidumbre para cada activo y la estabilidad de la identidad financiera, las de rentabilidad evalúan el comportamiento del rendimiento del activo, la de valoración indica la sobreestimación o subestimación del activo y la rentabilidad ajustada al riesgo muestra la eficiencia del activo frente al riesgo asociado. Gracias a este resumen, es evidente que se trata de analizar diferentes dimensiones financieras.

Con esta clase de factores, algunas posibles relaciones que pueden ser generadas por los árboles de decisión podría mostrar como altas volatilidades junto a bajas rentabilidades ajustadas al riesgo podrían ser descartados de reglas encontradas para los perfiles conservadores. Para individuos más tolerantes, aceptar volatilidades ascendentes, pero a cambio de rentabilidades acumuladas más altas podrían ser reglas más habituales. Para prototipos más neutrales, un equilibrio entre todas las

perspectivas puede llegar a ser lo más común, por lo que las variables de rentabilidad ajustada al riesgo pueden ser las preferidas.

También se podría anticipar como una combinación entre una volatilidad baja y un beta bajo, alto alfa de Jensen y una alta rentabilidad relativa mensual llegarían a lograr ser la combinación más repetida.

De todas maneras, los árboles de decisión muestran ser adecuados para el análisis que se pretende hacer, porque estos modelos se responsabilizarán de encontrar la relación óptima e identificar las conjunciones de variables que maximicen la rentabilidad ajustada al perfil del inversor mediante reglas basadas en datos de corte transversal.

## **4.2. Software y uso de librerías**

Para todas las tareas que tienen que ver con la recolección, procesamiento y análisis de los datos se han llevado a cabo con el lenguaje de programación llamado R.

Este lenguaje y entorno de software es uno de los principales lenguajes en cuanto a realizar acciones dentro del análisis estadístico, la visualización de gráfico y el aprendizaje automático. Además de ser una herramienta *open source*, que la hace de carácter abierto, su buena integración de materiales, así como su amplia comunidad que han contribuido (y siguen haciendo) en la creación de nuevos paquetes<sup>44</sup>, hacen que esta plataforma sea apropiada para las intenciones que plantea hacer el proyecto.

Así es posible explicar que dentro de R existen las librerías, que son paquetes en los que se encuentran colecciones de funciones, datos y código compilados<sup>45</sup>. Gracias a estas, se permite una simplificación y aumento de la eficiencia y productividad de las labores que se pretenden alcanzar.

Por esto, la librería usada para la obtención de los datos financieros de las 20 empresas consideradas fue *quantmod*<sup>46</sup>, la cual, se encargó de facilitar la descarga de los datos bursátil desde *Yahoo Finance*.

Para la gestión y transformación de los datos financieros se han dispuesto de diversos paquetes. Por un lado, *dplyr* proporcionaba funciones de manipulación y filtrado de los datos<sup>47</sup>, *tidyr* para la estructuración y limpieza de los datos<sup>48</sup>, *lubridate* para manejar

datos propios de formatos de fechas temporales<sup>49</sup> y *tidyquant* para cálculos y transformaciones de los datos.

Sobre el manejo de las series temporales, se ha contado con las librerías *xts* y *zoo*<sup>50</sup>, donde las dos se especializaban en funciones para datos de este tipo.

Con respecto al análisis exploratorio de los datos previo al modelado, se ha usado los paquetes *car* y *gplots*. La primera contiene funciones clave para evaluar la distribución de los datos con pruebas de homogeneidad de varianza y normalidad, en comparación con la segunda enfocada en la representación de ilustraciones avanzadas que explotan visualmente las relaciones entre variables<sup>51</sup>.

Por último, para la visualización de los datos se ha utilizado la librería *ggplot2*, esencial para la creación de gráficos de calidad que permite visualizar los resultados obtenidos de los modelos.

## **4.3 Tratamiento de los datos**

### **4.3.1 Procesado de datos**

Comenzando ya a detallar los pasos seguidos en el orden que se han aplicado para hacer efectivo el análisis, con el objetivo de mejorar la comprensión que merece el flujo de trabajo del proyecto, el primer paso ha consistido en la recopilación, filtrado y limpieza de los datos obtenidos para poder preparar las variables necesarias para su posterior estudio.

Para la extracción de los datos, se ha usado la función *getSymbols* para la recopilación de la información bursátil directamente desde *Yahoo Finance* para las 20 empresas que se han seleccionado dentro del IBEX 35, así como se han conseguido los datos del propio índice como referencia. Como se ha comentado en puntos anteriores, se ha optado por especificar dentro de la función la frecuencia mensual basada en los motivos comentados previamente (evitar valores NA, perspectiva más a largo plazo representativas). Añadido a la frecuencia, también se detalla el período comprendido entre los años 2016-2024 para garantizar que coincidan los datos para todas las empresas.

Siguiendo con esto, con los datos predeterminados que se consiguen con *getSymbols*, hay algunas variables que no son relevantes en el estudio, y por ello son eliminadas,

al no aportar ningún valor adicional a la construcción de los modelos. Los factores descartados han sido el precio de apertura, del máximo, del mínimo y el volumen de negociación, ya que a partir de estos no se calcula ninguna de las variables financieras que se han tenido en cuenta en el trabajo, por lo que carecen de valor.

Posteriormente, se han calculado todas las métricas en las que se fundamentarán los modelos para crear las reglas en las que se justificarán los árboles de decisión. A través de esto, se realizan las operaciones pertinentes para hacerse con la volatilidad, la beta, los tres tipos de rentabilidades, y las dos clases de rentabilidades ajustadas al riesgo.

La única variable que ha tenido que recibir un trato un tanto más especial por su condición ha sido la calificación crediticia, debido a que al ser una variable categórica, ha tenido que sufrir una transformación hacia un factor ordenada para una apropiada interpretación posterior por parte de los modelos servidos sobre la solvencia de las compañías expuestas, manteniendo el nivel jerárquico que representaba la variable inicialmente.

Con todo esto, tras el procesamiento de cada empresa realizado de forma independiente, se ha pasado a unir cada objeto que reunía los datos de cada negocio en un solo único *dataframe*, (para facilitar el manejo de todos los datos) el cual se estructuraba sustentado en que una observación correspondía a una empresa concreta en un mes determinado.

#### **4.3.2 Transformación datos transversales**

Dado que la información de los precios de cierre mensuales de las acciones y sus variables derivadas, hasta el momento son de corte temporal, esto supone un contratiempo en la aplicación de los modelos de árboles de clasificación por la naturaleza misma de este tipo de datos, debido fundamentalmente a la independencia de las observaciones en el conjunto de datos disponible <sup>52</sup>.

Si bien por un lado, los datos temporales poseen la característica de que se muestra la evolución temporal de las variables recopiladas, esto lleva a la creación de una dependencia entre las observaciones de variables de esta clase por su propiedad secuencial, ya que los datos recogidos siempre van a depender de su antecesor (autocorrelación<sup>53</sup>).

Esta característica de las series temporales, choca de lleno con la premisa de que existe independencia entre las observaciones de los datos. Por ello, surge la necesidad de transformar los datos hacia un corte transversal, ya que esta clase de datos tienen particularidades distintas, siendo independientes las observaciones al reflejar el comportamiento de las variables en una instantánea del tiempo, creando una conversión atemporal<sup>54</sup>.

No obstante, una de las ventajas de los árboles de clasificación es que tampoco existe un impedimento total y estricto en ser usados sobre series temporales, pero esto podría ser visto como una equivocación, ya que estos modelos no disponen de los mecanismos necesarios para manejarse ante este tipo de series y como resultado serán sustancialmente bajos en su precisión sobre sus predicciones<sup>55</sup>.

Por estas razones, para consolidar la transformación a la clase deseada que en este caso es la transversal, se ha optado por utilizar la mediana como medida de referencia central, debido a la capacidad de esta métrica de suavizar el efecto de los valores atípicos en sus resultados, causando una mejor captación del comportamiento promedio de la variable correspondiente. De tal forma, se prefiere esta medida frente a la media, por la incapacidad de esta última al verse adversamente influenciada por *outliers*<sup>56</sup>.

Asimismo, y con el mismo enfoque, para la variable categórica de la calificación crediticia sobre las entidades financieras, que es la única que recibe un tratamiento especial por su condición, se ha utilizado la moda (valor más frecuente en la distribución de una variable) para la transformación transversal de esta variable, para captar la puntuación más repetida que obtuvo cada compañía durante el tiempo escogido.

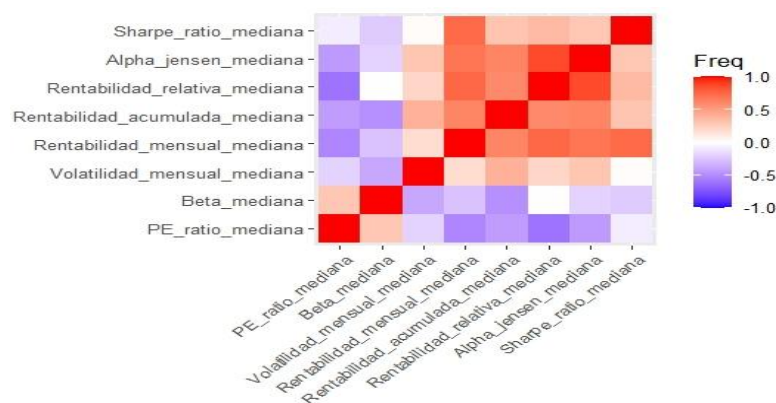
#### **4.3.3 Análisis exploratorio**

El análisis exploratorio es una parte esencial dentro del análisis de los datos ya que permite ser entender la estructura de los datos, así como se relación entre las variables, la distribución que tienen, identificar valores atípicos, etc. Con estas acciones, se consigue examinar y resumir visualmente el conjunto de datos sobre sus características primordiales, por lo que básicamente es una tarea de índole descriptiva<sup>57</sup>.



Al no haber un proceso cerrado, formal y estricto, es capaz de enfocar este proceso de diversas formas<sup>58</sup>. Por el contexto que ata e la situaci n actual del proyecto, las distribuciones, as  como valores at picos de los datos, aun habiendo sido obtenidos usando logaritmos, es esperable que las distribuciones sean m s sim tricas y con menor ruido, pero esto no garantiza la normalidad, por lo que la verificaci n sigue siendo una tarea trascendente para la exploraci n<sup>59</sup>.

Por ello, el foco central en esta parte exacta del trabajo ha sido la compresi n existente entre las variables actuales del conjunto de datos. Para poder hacer esto, se ha optado por crear un mapa de correlaciones que permitiera representar sencillamente esta coyuntura.



Ilustraci n 3: Mapa de calor de correlaciones (elaboraci n propia)

Como se puede observar, la matriz de correlaciones<sup>60</sup> conseguida es altamente valiosa por la cantidad de relaciones que se pueden resaltar en esta ilustraci n. Esto se fundamenta en que la matriz es sumamente diversa en el rango de valores, obtenido, mostrando diferentes relaciones subyacentes en la estructura de los datos. Sin embargo, cabe recordar que exista correlaci n, no significa causalidad, solo muestra una asociaci n, no una relaci n de causa-efecto<sup>61</sup>.

Entrando m s en detalle, sobre las correlaciones positivas m s fuertes, se encuentra la m s destacada que es la rentabilidad relativa mediana y el Alfa de Jensen (0.86), seguida por: rentabilidad mensual mediana - rentabilidad relativa mediana (0.75), rentabilidad mensual mediana - Sharpe ratio mediana (0.7408), rentabilidad mensual mediana - Alfa de Jensen mediana (0.69), rentabilidad acumulada mediana - Alfa de Jensen mediana (0.62), rentabilidad mensual mediana - rentabilidad acumulada mediana (0.62) y rentabilidad acumulada mediana - rentabilidad relativa mediana (0.6).

Estas correlaciones fuertes indican en su definición que si una variable aumenta la otra imitará el comportamiento y también sufrirá aumentos. De esta forma, aunque también cabría esperar, las variables del grupo de rentabilidad y de rentabilidad ajustada al riesgo tienen altas correlaciones positivas. Aunque esto era predecible, al poseer correlaciones tan fuertes, es posible que haya existencia de multicolinealidad entre las variables halladas, lo que marca una profundización necesaria sobre este hecho con el objetivo de mejorar la estructura de los datos para la futura mejora de estabilidad y precisión de los futuros modelos<sup>61</sup>.

En cuanto a las correlaciones negativas más significativas, la más sólida es la de la rentabilidad relativa mediana - PE ratio mediana (-0.61), y a continuación por la rentabilidad mensual mediana - PE ratio mediana (-0.52).

Estas correlaciones negativas más robustas ejemplifican relaciones inversas, es decir, que las variables se mueven en sentidos opuestos. Por esto, la variable de valoración y variables de rentabilidad se mueven en direcciones negativas, por lo que puede ser que empresas mejor valoradas pueden no dar los retornos que se les espera que den.

Como deducciones sobre los resultados, se resalta que las métricas de rentabilidad tienen correlaciones fuertes entre sí, lo que indica que los retornos de los activos tienden a ser consistentes; el Alfa de Jensen y el Sharpe Ratio están fuertemente relacionados con la rentabilidad, lo que confirma que los activos con mejores retornos suelen superar al mercado y ofrecen eficiencia ajustada por riesgo; la ratio PER muestra correlaciones negativas significativas con la rentabilidad; el beta tiene correlaciones negativas con la rentabilidad, lo que implica que activos con mayor sensibilidad al mercado no necesariamente generan mejores retornos.

Por todo esto, la dirección a tomar a partir de la matriz de correlación es indagar sobre la multicolinealidad entre variables para saber cuáles son las que más relacionadas están entre sí y así poder justificar que factores pueden ser eliminados (anexo 3). Dada esta razón, se ha optado por el FIV (Factor Inflación Varianza), al ser capaz de aislar el efecto combinado de todos los predictores sobre cada variable<sup>62</sup>.

Tras la aplicación del FIV sobre el conjunto de datos actual, antes de eliminar cualquier variable, se ha comprobado que los valores de FIV más altos son el de rentabilidad mensual y el de rentabilidad relativa. Por esta razón, según las interpretaciones generales estipuladas, valores superiores a 5 indican alta

multicolinealidad. Al estar estas dos variables por encima de 6, ello sugiere que hay una alta correlación.

Variable	preFIV	postFIV
Beta_mediana	1.89	1.89
Volatilidad_mensual_mediana	1.31	1.31
Rentabilidad_mensual_mediana	6.57	NA
Rentabilidad_acumulada_mediana	2.57	2.57
Rentabilidad_relativa_mediana	6.39	NA
Alpha_jensen_mediana	4.63	4.63
Sharpe_ratio_mediana	2.98	2.98

Ilustración 4: Tabla FIV comparativa (elaboración propia)

Por este motivo, se ha decidido eliminar estos parámetros y volver a realizar el mismo procedimiento para volver a analizar el FIV tras el descarte de variables. Es palpable la reducción de la colinealidad sustancialmente, por lo que se ha conseguido una disminución de la redundancia entre variables del conjunto.

Valor de VIF	Grado de Muticolinealidad
Hasta 5	Débil/Moderado
De 5 a 10	Elevado
Mayor a 10	Muy elevado

Ilustración 5: Interpretación valores FIV (fuente: Profesor Data, 2025)

Añadido a esto, al ser la base de datos disponible de pequeñas dimensiones, se ha decidido hacer la prueba de Shapiro-Wilk<sup>63</sup> para evaluar si la distribución de las variables disponibles sigue o no una distribución normal<sup>64</sup>, factor que merece la pena constatar para conocer si las variables numéricas sufren de sesgo, si los árboles de decisión son los modelos idóneos para estos datos transversales, al hacer no basarse en el supuesto de la normalidad en los datos (métodos no paramétricos<sup>65</sup>), e intuir como los árboles pueden hacer los cortes en sus divisiones por nodos según la distribución encontrada.

Tras aplicar la prueba de Shapiro-Wilk ([apéndice 1](#)), es tangible como la mayoría de las variables numéricas no se aproximan a una distribución normal pese al uso de logaritmos para su cálculo, ya que solamente el beta y el Alfa de Jensen son las

únicas que no presentan suficiente evidencia para ser descartadas de seguir una distribución normal.

Para reforzar visualmente esta situación (apéndice 2), se han utilizado los *qq-plots*<sup>66</sup> (gráficos de cuantil cuantil), para representar como hay suficientes valores atípicos en la distribución de las variables, lo cual ha terminado afectando a la distribución de las variables y por tanto determinar que no siguen distribuciones normales. Entrando más en detalle, la variable de la ratio PER y la ratio Sharpe son las que presentan las colas más pesadas (extremos más pronunciados), mientras que la volatilidad mensual y la rentabilidad acumulada siguen patrones más curvos (muestra de asimetría).

Esto justifica y refuerza la idea de dos elementos. Por un lado, la aplicación de la mediana como medida central para reflejar el comportamiento promedio de las variables en su evolución, y por otro, la aplicación de los árboles de decisión dentro de la rama de los métodos no paramétricos, para la clasificación de estos datos y por tanto, para realizar la tarea de clasificación en este proyecto.

Por último, también se ha considerado relevante analizar si hay posibles diferencias significativas entre las medianas de las empresas si se agrupan según al sector al que pertenecen. Para ello, se ha contado con las pruebas *Kruskal-Wallis*<sup>67</sup> y *Anova*<sup>68</sup>, para poder verificar la existencia de posibles diferencias por sector. Según los resultados obtenidos (apéndice 3), se puede constatar que hay diferencias significativas dependiendo del sector del que la empresa es miembro.

Estos resultados exploratorios evidencian que, para el perfil de riesgo correspondiente, el sector puede llegar a tener un peso significativo dentro de la selección de la acción. Además, que la ratio PER sea independiente según el sector, pero tenga colas pesadas en su distribución, demuestra que es una variable directamente influenciada por las expectativas, a menudo, irracionales o especulativas que tiene el mercado sobre un negocio. En adición a esto, que la ratio de Sharpe (relación volatilidad-rentabilidad), el cual se encuentra en la misma situación, sugiere que las colas pesadas se pueden deber por eventos externos que afectan por igual a todos los sectores.

Con esta aproximación, se ha conseguido un potencial aumento de la estabilidad, precisión e interpretación en los posteriores modelos, que se enfocarán en crear relaciones más independientes y robustas a través de esta nueva estructura de la información.

#### **4.3.4 Introducción variable binaria**

Pese a ya tener una base de datos que reúne las características precisadas para realizar la misión encomendada, faltaría por establecer el último paso dentro del flujo de trabajo, el cual sería la creación e introducción de una variable binaria predictora sobre la que los distintos modelos se entrenarán en base a esta para luego realizar sus predicciones futuras.

La estrategia con la que se sustenta este paso, es que se necesita crear una variable binaria que refleje la inclusión o descarte de adquirir la acción de cualquiera de las empresas que forman parte del abanico del que se dispone, apoyándose en criterios concretos que se ajusten a las necesidades de cada perfil de riesgo. Por lo cual, el funcionamiento sería implementar una función, que se encargue de recorrer todas las variables de la base de datos, comprobando si los valores rebasan o se quedan atrás de los umbrales de puntuación establecidos, otorgando una puntuación por cada resultado sobre el rendimiento en cada variable, para finalmente, hacer una suma sobre todos los apartados y realizar una decisión binaria, donde si se supera el límite determinado se incluye en la cartera y se rechazaría en caso contrario<sup>69</sup>.

La asignación de puntuación para cada parámetro no es fija ya que no existen umbrales universalmente aceptados y que depende del contexto para cada activo financiero, aunque, de todas formas, se han seguido umbrales orientativos y aproximados para llevar a cabo la función mencionada antes para cada perfil de riesgo.

La jerarquía de importancia de variables en el sistema de puntuación también dependerá directamente del tipo de perfil al que se aplique. Por ello, un inversor prudente frente al riesgo dará más relevancia a las variables de volatilidad y al sistema de calificación crediticia, y con un enfoque secundario en la rentabilidad ajustada al riesgo. Para los más neutrales, se buscaría un equilibrio entre todas las variables, por lo que el peso de todas será similar entre ellas. Por otro lado, para los perfiles más tolerantes, se aportará una mayor significatividad a la rentabilidad<sup>70</sup>.

##### **4.3.4.1 Umbrales variables volatilidad**

Para la volatilidad se ha considerado que los inversores deberían de estar dispuestos a soportar volatilidades no mayores del 2% para los conservadores; menor del 7% para los neutros y un 15% para perfiles más tolerantes<sup>71</sup>. Para el beta, perfiles

conservadores desearían volatilidades menores que el mercado, por lo que un valor inferior a 1 sería el buscado; mientras que un neutro se asemejará a valores cercanos a 1 y un agresivo podría llegar a aceptar un beta no superior a 2 (el precio de la acción fluctúa el doble que el del mercado)<sup>72</sup>.

En cuanto a la calificación crediticia, para los conservadores estos no admitirían invertir en compañías con *ratings* por debajo de A- (salvo excepción variable a BBB+), los neutrales podrían llegar a valorar *ratings* hasta BBB y los agresivos pueden llegar a aceptar a negocios con calificaciones de BBB- (el mínimo en la distribución de las 20 empresas disponibles)<sup>73</sup>.

#### **4.3.4.2 Umbral variable rentabilidad**

Para la única medida de rentabilidad que queda tras el análisis exploratorio, que es la rentabilidad acumulada mediana mensualmente entre los años 2016-2024. Para establecer los límites a superar para el perfil conservador y neutro, se ha tomado en consideración la rentabilidad esperada que suelen otorgar los fondos conservadores de los bancos españoles como *benchmark* a batir, dado que las acciones de empresas pertenecientes al IBEX 35 automáticamente representan un mayor riesgo por la naturaleza del producto financiero<sup>74</sup>.

Por ello, para perfiles conservadores se exige una rentabilidad acumulada mínima mayor de un 3%, para tipos neutrales una rentabilidad mínima superior al 4% y para inversores más tolerantes frente al riesgo una rentabilidad que supere el 7%<sup>75</sup>.

#### **4.3.4.3 Umbral variable de valoración**

Buscando los mismos umbrales ahora sería el turno de la variable de valoración de activos, siendo este la ratio PER. Comúnmente, si el PER de una empresa es elevado durante un tiempo cuantioso, esto se suele relacionar con empresas con altas expectativas, haciéndolas más arriesgadas; caso contrario para las que tienen valores menores, ya que pueden reflejar negocios más sólidos y consolidados que los hacen apuestas más estables<sup>76</sup>.

El consenso general es que un PER bajo está entre niveles de 0-10 que sería el que mejor se ajusta para los inversionistas conservadores, niveles entre 10-20 es un PER intermedio indicado para perfiles neutros y resultados superiores a 20 es considerado alto y el idóneo para los tipos más tolerantes<sup>77</sup>.

#### **4.3.4.4 Umbrales variables de rentabilidad ajustada al riesgo**

Para finalizar, se analizan las dos variables que se tienen sobre la rentabilidad ajustada al riesgo. En cuanto al ratio de Sharpe, como cuanto más alto sea este, mayor rentabilidad por unidad de riesgo asumida se está consiguiendo, se establece que para los conservadores mínimo necesitarán un valor igual o mayor de 1 para realizar la inversión, entre 0.5 y 1 para perfiles neutros y para los agresivos mayor de 0.5<sup>78</sup>.

Sobre el alfa de Jensen, cuanto mayor sea el indicador, mayor será la rentabilidad generada en comparación con el *benchmark*. Por ello, un alfa superior o igual a 0% es el deseado para los que tienen más aversión al riesgo, los neutrales se pueden permitir una ligera desviación conforme el *benchmark*, por lo que valores entre -1% y 2% serán los escogidos y para los agresivos se estipula que se encuentre esta métrica entre -2% y 3%<sup>79</sup>.

Se ha elaborado un cuadro resumen que sintetiza todo lo discutido en estos subapartados de una forma más visual ([apéndice 4](#)).

#### **4.4 Modelos y técnicas utilizadas**

En esta sección se especifican los detalles necesarios para explicar las particularidades necesarias de los árboles de decisión contruidos, así se precisa la estrategia utilizada para mitigar el problema del sobreajuste típico de este tipo de modelos.

Los modelos base empleados para abordar el planteamiento que se viene haciendo a lo largo de todo el proyecto han sido mediante *rpart* y *randomForest*.

El primero, que se utilizó a través del paquete que recibe el mismo nombre (*rpart*), ha servido para crear árboles de decisión altamente interpretables, los cuales permiten ver las divisiones basadas en las variables clave y delimitando las reglas de clasificación claras que lo llevaron a ello<sup>80</sup>.

El segundo, que también tiene la función en el paquete nombrado de la misma forma (*randomForest*), se destinó al mismo objetivo pero buscando al mismo tiempo la reducción de la varianza y el aumento de la robustez del modelo. Esto lo consigue a través de combinar varios árboles con el *bagging*. Este enfoque mitiga el sobreajuste al promediar las predicciones de árboles independientes e introduce aleatoriedad en

la selección de variables en cada división, lo que diversifica las reglas y mejora la generalización<sup>81</sup>.

Otro aspecto relevante es la significatividad que tuvo cada variable en la clasificación de cada activo. Ambas funciones permiten obtener una clasificación sobre este hecho, solo que *rpart* lo cuantifica midiendo la pureza del nodo<sup>82</sup> y *randomForest* lo puede hacer o bien con la disminución media de la precisión o con la reducción del índice Gini<sup>83</sup>.

#### **4.4.1 Estrategia de optimización de los hiperparámetros**

Lo último que se tuvo en cuenta sobre estos modelos base fue la problemática que sufren los árboles de decisión de ser propensos a caer en errores propios del sobreajuste a los datos. Para mantener un equilibrio entre las dimensiones de precisión y representatividad, se ha optado por modificar los hiperparámetros en ambos modelos, implantando una semilla aleatoria para poder reproducir los resultados aleatorios.

En *rpart* se modificó el criterio *cp* (10 *folds*) para controlar la complejidad del árbol (a más alto más simple), el *minsplit* (secuencia: 5, 10, 15, 20) como el mínimo de observaciones para dividir un nodo y el *maxdepth* (secuencia: 3, 5, 7, 9) para la profundidad máxima del árbol. Se priorizó la minimización del error de validación (*xerror*) y la maximización del AUC mediante validación cruzada manual (5 *folds*). La medición de la relevancia de variables se midió con la pureza del nodo<sup>84</sup>.

En contraste *RandomForest*, que ya de por si es resistente al sobreajuste, se optimizó el *mtry* para saber el número de variables aleatorias a tener en cuenta en la división del nodo, el *splitrule* sobre la forma en que se crean las particiones en los datos (*gini* o *extratrees*) y el *min.node.size* para controlar el sobreajuste fijando el número mínimo de observaciones para realizar la división de un nodo. Con la combinación de estos tres se ha buscado la maximización del AUC, de la sensibilidad y de la especificidad, mediante el uso validación cruzada (10 *folds* x 3 repeticiones). El establecimiento de la jerarquía de significatividad de las variables se realizó con la permutación, es decir, cuantificando cuanto se reduce la precisión de la predicción del modelo al aleatorizar cada variable<sup>85</sup>.

La búsqueda de los mejores hiperparámetros para cada modelo dependiendo del tipo de inversionista se ha llevado a cabo a través de todas las combinaciones posibles del



conjunto predefinido de valores para los hiperparámetros, con el objetivo de identificar la combinación que proporciona el mejor rendimiento del modelo.

#### **4.5 Conjunto de entrenamiento y métricas de evaluación**

La estrategia a implementar para ejecutar el entrenamiento del modelo, así como la prueba y la optimización de los hiperparámetros, viene influenciada directamente por las dimensiones que tiene el conjunto de datos transversales, el cual es de un tamaño limitado al solo disponer de 108 observaciones. Con tal de garantizar la robustez y evitar caer en sobreajustes, se ha optado por una partición de un 80% de los datos para el entrenamiento y el 20% restante en el de prueba<sup>86</sup>.

Además, es previsible que exista un cierto desbalance de clases al solo tener 20 acciones de empresas a clasificar, por lo que es previsible que se tengan que utilizar técnicas que intenten solventar este contratiempo. Para ello, se optaría por utilizar el método de validación cruzada estratificada como método de optimización de hiperparámetros. Esta estrategia permite aprovechar mejor los datos disponibles y asegurar una representación adecuada de las distintas clases en cada iteración del proceso de entrenamiento<sup>87</sup>.

En cuanto a las métricas de evaluación, se tendrán en cuenta aquellas más comunes cuando se trata de evaluar un modelo de clasificación.

El primer grupo de métricas se extrae directamente de la matriz de confusión. De esta surgen varios parámetros, que se pueden asociar a cinco grupos distintos. En primer lugar, está la exactitud, que servirá para ver cuantas predicciones totales fueron aciertos, a través de la cual, también surge la tasa de error para comprobar la proporción de fallos. Seguido de ello, se encuentra precisión para ver el porcentaje de casos positivos detectados. Por otro lado, está la sensibilidad para representar la tasa de verdaderos positivos correctamente discriminados y la especificidad como la tasa de verdaderos negativos correctamente clasificados. Por último, se halla el f1-score que consigue medir el equilibrio existente entre la precisión y la sensibilidad del modelo (anexo 4)<sup>88</sup>.

El otro grupo de métricas sería enfocado en probabilidades, con las métricas AUC y curva ROC, que analizan la relación entre la tasa de verdaderos positivos y la de falsos positivos a distintos umbrales de decisión<sup>89</sup>. Complementaría a estas dos, surge

también el estadístico Kappa, el cual mide la calidad de las predicciones hechas en comparación a una clasificación aleatoria<sup>90</sup>.

#### **4.6 Limitaciones del estudio**

Por el desarrollo del estudio, se han generado una serie de elementos que sería interesante cubrir en estudios futuros si siguen esta línea de investigación, al no estar cubiertos ni tratados como es debido en este proyecto.

Por una parte, el horizonte temporal es reducido si la frecuencia temporal se mantiene en formato mensual para que sea considerado el estudio de largo plazo de manera rotunda, debido a que solo con los años 2016-2024 no se pueden tomar en cuenta ciclos completos financieros ni el efecto que tienen en los precios de cierre de las acciones de empresas pertenecientes al índice bursátil del IBEX 35. Ampliar el intervalo hasta el año 2000 sería una alternativa que no se ha llevado a cabo en este trabajo por mantener la homogeneidad de los datos entre las empresas recopiladas.

Asimismo, la consideración de los perfiles de riesgo, aunque añade valor a la investigación al adaptarse a las necesidades del inversor, carece de un ajuste particular y a medida del perfil del individuo, ya que solamente considerar tres perfiles es una forma reduccionista y simplista que se toma como guía general, pero que falla en ser totalmente precisa para ajustarse a todos los tipos posibles de inversionistas.

Además, se ha procedido a realizar un trabajo que ya dependía de un sesgo de selección que ha dejado a una gran parte de empresas formadoras del índice de referencia, lo cual vuelve a recalcar el ánimo de representatividad en detrimento de la precisión máxima alcanzable.

Igualmente, como los modelos funcionan con datos históricos siempre existe la posibilidad de que no se adhieran perfectamente a comportamientos futuros volátiles que no hayan sido representados en los datos y por tanto los modelos no hayan podido aprender de estos patrones. De la misma forma, futuras investigaciones podrían tratar de crear modelos híbridos entre los árboles de decisión para la tarea de la clasificación junto a la captación de la temporalidad con otros modelos, como por ejemplo ARIMA<sup>91</sup> (abreviatura de Media Móvil Integrada Autoregresiva).

Por último, no se han tenido en cuenta variables que podrían añadir más contexto a la clasificación que realizan los modelos, al no haber recogido variables

macroeconómicas como tasas de interés, ni tampoco el sentimiento del mercado mensual, lo cual podría haber sido capaz de enriquecer aún más las predicciones de los modelos.

## **5. RESULTADOS**

Los hallazgos obtenidos se han organizado en cuatro secciones distintas donde cada una profundiza en un énfasis concreto.

La primera se centra en el entrenamiento de los modelos y la extracción de reglas en el *train set* tanto para *rpart* como *randomForest*, viendo las reglas de decisión para cada perfil, la jerarquía de importancia de las variables en la clasificación y la elaboración de la tarea de optimización para los hiperparámetros.

La segunda se ha focalizado en la evaluación del *test set*, tanto de los modelos genéricos como de los modelos con los hiperparámetros optimizados, mediante las métricas de rendimiento y la matriz de confusión, aprovechando también para hacer comparaciones del rendimiento entre perfiles.

La tercera en cómo se relacionan las reglas y descubrimientos sobre la teoría financiera anterior, la coherencia que tienen con los perfiles de riesgo diferenciados y señalar los casos discrepantes.

El cuarto y último, se mencionarían las limitaciones operativas por la sensibilidad a los cambios temporales y el impacto de la selección de las empresas consideradas en la muestra usada.

### **5.1 Entrenamiento de los modelos**

#### **5.1.1 Árboles genéricos**

El árbol de *rpart* para el perfil conservador con un desbalance de 15:5 ("No incluido" vs "Incluido") identificó reglas clave: *rating* crediticio  $\geq$  BBB+ (44% importancia), ratio Sharpe  $>0.32$  (19%) y aparecen de forma encadenada la volatilidad  $<1.54$ , la ratio PER  $>7.92$  y los sectores de energía y consumo (12%). La exigencia de PER mínimo, puede resultar inusual en enfoques conservadores, lo que se relaciona a la sugerencia de evitar *value traps* en sectores cíclicos<sup>92</sup>, mientras que la irrelevancia de beta (12%),

no se debe a correlación con volatilidad ( $r = -0.38$ , ilustración 2). Por el lado de *randomForest* para el mismo perfil (1000 árboles), este confirma que el *rating* crediticio, la ratio Sharpe y la volatilidad son predictores estables, pero reduce la relevancia de PER y sector y aumenta la de beta (comparativa en [apéndice 5](#)).

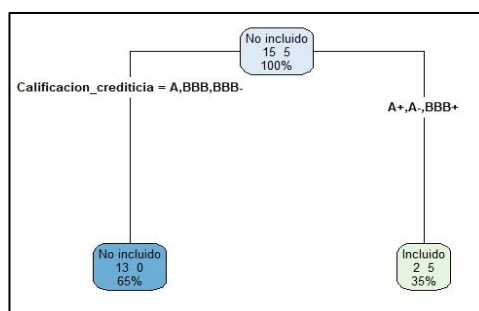


Ilustración 6: Árbol de decisión conservador genérico *rpart* (elaboración propia)

Bajo las mismas condiciones pero para los agresivos, *rpart* se configuró con un ligero menor desbalance de 13:7 (“No incluido vs “Incluido”), generando las siguientes sustanciales combinaciones: rentabilidad acumulada  $> -21\%$  (45% de importancia), enlazando al mismo nivel alfa de Jensen  $> 0.3$  y beta  $< 0.93$  (17%), ratio de Sharpe  $> 0.05$  (15%) e inclinándose por sectores de energía, salud, industrial y tecnología (12%). La rentabilidad mínima acumulada exigida negativa, puede reflejar la posible adaptación al volátil contexto temporal, prefiriendo empresas en los sectores seleccionados con altas posibilidades de rebote (alta penalización pero rápida recuperación<sup>110</sup>). En cambio, RF (1000 árboles) destaca la calificación crediticia como la más importante, seguida muy de cerca por la rentabilidad acumulada. La divergencia entre ambos subraya el clásico *trade-off* entre la rentabilidad flexible cíclica (*rpart*) y el equilibrio entre riesgo y retorno (RF), como enfoques distintos pero complementarios, pese al desbalance de clases (comparativa en [apéndice 6](#)).

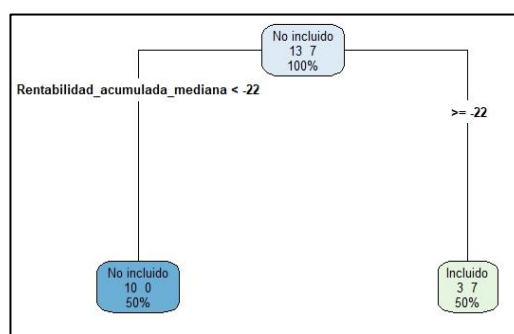


Ilustración 7: Árbol de decisión tolerante genérico *rpart* (elaboración propia)

Finalmente, en cuanto al tipo neutral, *rpart* estableció un muy ligero desbalance de clases 8:12 (“No incluido” vs “Incluido”), sentando las siguientes normas primordiales: alfa de Jensen  $\geq -0.0073$  (35% de importancia), una ratio PE  $< 9.8$  (15% importancia), una ratio de Sharpe  $> 0.085$  (10%), preferencia por sectores energético y sanitario ( $<10\%$ ) y volatilidad mensual  $< 1.9$  ( $<10\%$ ). La propensión hacia sectores energéticos y sanitarios (también identificada en agresivos) sugiere que estos dominaron los patrones de rentabilidad-riesgo durante el período analizado. Por el lado de RF (1000 árboles), este reitera el alfa de Jensen y el PE ratio como variables principales, pero otorga un descenso significativo de la relevancia de la rentabilidad acumulada como predictor (comparativa en [apéndice 7](#))

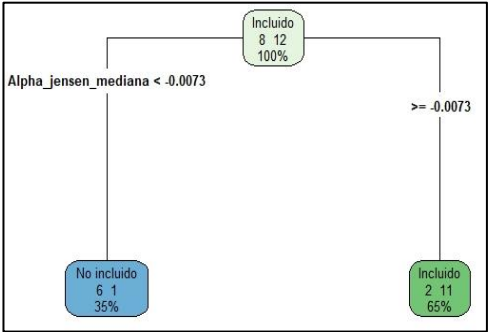


Ilustración 8: Árbol de decisión neutral genérico *rpart* (elaboración propia)

Los errores en RF medidos con el *Out Of Bag* (OOB) y en *rpart* mediante la pureza del nodo inicial y final, aunque son esperados por el alto desbalance entre clases y el reducido número de la muestra, no invalidan estos patrones preliminares sobre las variables significativas, pero resaltan el uso de utilizar técnicas de validación cruzada para mitigarlo. Añadido a esto, *rpart* tiende a tener más problemas de sobreajuste (medido con el xerror) pero mejor precisión en los nodos finales, por lo que *rpart* puede llegar a ser más preciso, pero RF más estable y generalizable. Esto implica que se puede hacer un uso complementario entre *rpart* hacia un enfoque de reconocimiento de tendencias y RF para posibles validaciones.

Perfil	Métrica	rpart	RandomForest (RF)
Conservador	Error Global	25% (inicial) → 0-28.6% (final)	20% (OOB)
	Error Clase Minoritaria	28.6% (Incluido)	60% (Incluido)
Tolerante	Error Global	35% (inicial) → 0-30% (final)	25% (OOB)
	Error Clase Minoritaria	30% (Incluido)	42.9% (Incluido)
Neutral	Error Global	40% (inicial) → 14.3-15.4% (final)	35% (OOB)
	Error Clase Minoritaria	14.3% (No incluido)	50% (No incluido)
General	Sobreajuste	Alto (xerror= 100% en neutral)	Bajo (estable por diseño)
	Interpretabilidad	Alta (reglas explícitas)	Media (importancia variables)

Ilustración 9: Tabla resumen métricas de errores de RF y *rpart* en el train set (elaboración propia)

### 5.1.2 Optimización de hiperparámetros

La optimización de hiperparámetros en *rpart* (método explicado en punto 4.4.1) sobre el perfil conservador se logró con una mezcla de *minsplit* = 5, *maxdepth* = 3 y *cp* = 0.01, consiguiendo un AUC de 0.9667, pero con una estructura simplificada: el nodo raíz se basó exclusivamente en la calificación crediticia ( $\geq$ BBB+, 40% importancia), aunque se mantuvieron como relevantes el Sharpe ratio (20%), el sector, la volatilidad y el beta (13%, respectivamente) como predictores secundarios. Esto se suma a una poda que redujo el error de validación cruzada (*xerror* = 0.2). Sobre RF, se encontró el óptimo en *mtry* = 2, *splitrule* = *extratree* y *min.node.size* = 5 y mismo AUC que *rpart*. Este modelo priorizó la calificación crediticia, seguida del sector energético, de la volatilidad y de la ratio Sharpe. Con esto parece que se confirma la relevancia de variables de riesgo y eficiencia ajustada, fijándose en solvencia institucional, eficiencia ajustada al riesgo y sector para el perfil con más aversión al riesgo (comparativa en [apéndice 8](#)).




Ilustración 10: Árbol de decisión conservador optimizado *rpart* (elaboración propia)

La tarea de optimización en *rpart* en cuanto al perfil tolerante, se adquiere con la combinación de *minsplit* = 10, *maxdepth* = 9 y *cp* = 0.14, la cual aunque no consigue un AUC excelente (0.85), se escoge por tener un error sobreajuste mínimo y significativamente mejor que el modelo predeterminado (*xerror* = 0.57). Se repite la calificación crediticia como predictor más importante con BBB+ y BBB- (31% importancia), seguido de la rentabilidad acumulada (22%), el alfa de Jensen (16%), la ratio de Sharpe y la ratio PE (12% ambas). El RF tolerante fue optimizado con *mtry* = 5, *splitrule* = *extratrees* y *min.node.size* = 1, obtuvo un excelente ROC = 0.9, Sensibilidad = 0.95 y una aceptable especificidad = 0.61, que estableció como más importante a la rentabilidad acumulada, teniendo detrás a *rating* crediticio, la ratio de Sharpe y el Alfa de Jensen (comparativa en [apéndice 9](#)).

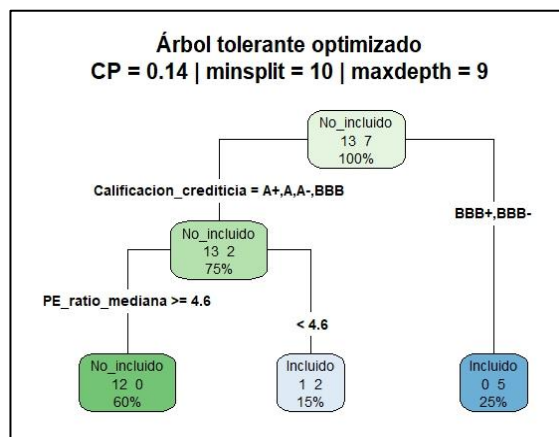


Ilustración 11: Árbol de decisión tolerante optimizado *rpart* (elaboración propia)

Finalmente, en el árbol *rpart* optimizado de la clase neutral, los parámetros responsables de ello son *minsplit* = 10, *maxdepth* = 3 y *cp* = 0.01, mediante los cuales se obtiene un AUC casi perfecto (0.98) y el error por validación cruzada mínimo posible (xerror = 0.625). El alfa de Jensen se erige como el predictor (27% de importancia), acechado por el PE ratio (21%), la índole del sector (16%) y el *rating* financiero (12%). Para el modelo RF en el perfil neutral optimizando sus hiperparámetros, los elegidos fueron *mtry* = 6, *splitrule* = *gini* y *min.node.size* = 1, con el que se obtiene un equilibrio entre ROC = 0.81, Sensibilidad = 0.5 y especificidad = 0.75. Además, el predictor más significativo fue la ratio PE, seguido del Alfa de Jensen y de la ratio Sharpe (comparativa en [apéndice 10](#)).

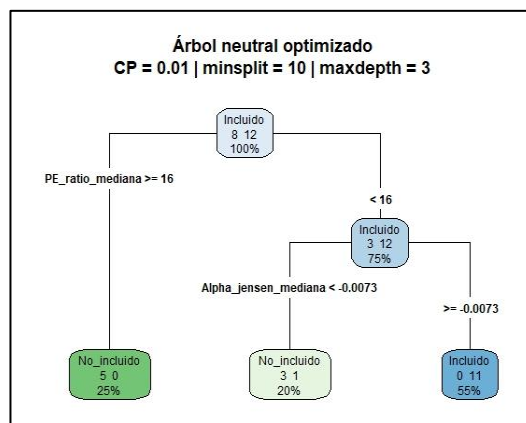


Ilustración 12 Árbol de decisión neutral optimizado *rpart* (elaboración propia)

La optimización de hiperparámetros permitió mejorar significativamente la capacidad predictiva de los modelos, reduciendo el sobreajuste observado en los árboles

genéricos (*rpart*), como evidencia la reducción generalizada del *xerror*. Estas mejoras pueden funcionar como posibles acercamientos hacia el objetivo principal del estudio al demostrar que los árboles de decisión, tras ajustes, son herramientas efectivas para clasificar acciones según perfiles de riesgo. Estos resultados subrayan cómo la optimización no solo incrementa la precisión, sino que también identifica variables clave (ej. *rating* crediticio, ratio de Sharpe) que simplifican la toma de decisiones, cumpliendo con los propósitos metodológicos establecidos.

## **5.2 Aplicación en el conjunto de prueba**

Habiendo conseguido complementar el entrenamiento de los modelos por perfil, finalmente se han conseguido cuatro modelos por clase de inversor, siendo dos genéricos y dos optimizados, por lo que hace un total de doce modelos a examinar en total. De esta manera, se procede a aplicar la evaluación final para establecer qué modelo funciona mejor para cada perfil y qué información se puede sacar de los tipos de árboles que se seleccionan y sobre los resultados que arrojan.

### **5.2.1 Evaluación modelos para el perfil conservador**

La producción de los modelos para este tipo de inversionista ha clarificado que el más destacado ha sido el RF optimizado. Esto se justifica en que ha sido el que mejor equilibrio ha conseguido entre todas las métricas conseguidas de entre todos los disponibles (más detalles en el [apéndice 11](#)). No obstante, cabe mencionar que el RF predeterminado logró tener valores perfectos en todos los parámetros, aunque pese a ello, se ha optado por descartarlo por ser tener un rendimiento irreal, el cual a priori, puede dejar entrever algún tipo de error por sobreajuste, posiblemente causado por memorizar el ruido del entrenamiento (OOB = 20% en puntos anteriores). Por ello, el RF optimizado se asume que sería más estable si se le añaden nuevos datos a la muestra, por la condición potenciada de este modelo en comparación al genérico. Contado con la información del [apéndice 8](#), luego el *rating* crediticio, el sector energético y la volatilidad son las variables críticas para los individuos de esta naturaleza.

Quitando este detalle anómalo, se puede afirmar que el rendimiento general de los modelos es aceptable, con un rendimiento satisfactorio para el *test set* ([apéndice 12](#)),



manifestado en la capacidad discriminativa en el gráfico de la curva ROC de todos los modelos ([apéndice 15](#)).

La matriz de confusión del RF optimizado refleja la solidez afirmada sobre el modelo, habiendo cometido solo un error de falso positivo (error al predecir "Incluido" cuando era "No incluido").




Ilustración 13: matriz de confusión RF conservador (elaboración propia)

### **5.2.2 Evaluación modelos para el perfil tolerante**

El análisis de los modelos para los sujetos más agresivos ha establecido que el que mejor desempeño ha tenido ha sido el árbol *rpart* genérico, con un claro dominio sobre los otros candidatos en prácticamente todos los indicadores ([apéndice 11](#)). En el caso particular de esta clase de inversores, merece la pena identificar como los modelos optimizados han acabado empeorando significativamente respecto a sus formas comunes. De este modo, y recuperando la información del [apéndice 6](#), se marca otra vez el *rating* crediticio como predictor clave, acompañado por la rentabilidad acumulada y la ratio de Sharpe.

Los errores más flagrantes se han cometido en el apartado de especificidad ([apéndice 13](#)), es decir, que han cometido mayormente errores de inclusión sobre acciones que en la realidad no eran incluidas. Esto resalta el factor de que un inversor arriesgado, aunque asuma más incertidumbre, no por ello tiene que sobreexponerse a volatilidades innecesarias. Como consecuencia, la capacidad discriminativa de 3 de 4 modelos es altamente indeseable en su ejercicio ([apéndice 15](#)).

La matriz de confusión del *rpart* no optimizado demuestra el rendimiento adecuado que despliega para este perfil en este contexto. Sin embargo, al tener un Kappa moderado, alrededor de un tercio de las predicciones podrían no ser reproducibles con nuevos datos. Esto indica que, aunque el modelo es útil para identificar acciones aptas en condiciones similares a las históricas, su capacidad para generalizar en contextos de alta volatilidad o cambios estructurales del mercado es limitada.




Ilustración 14: matriz de confusión *rpart* genérico tolerante (elaboración propia)

### **5.2.3 Evaluación modelos para el perfil neutral**

El árbol que demostró la mejor producción de resultados para los perfiles neutrales ha sido el modelo optimizado de *rpart*. El factor determinante para la elección de este modelo ha sido en base a la superioridad mostrada en todas las métricas salvo en el AUC, en la que es ligeramente inferior (<3%) frente al RF optimizado y al RF predeterminado ([apéndice 11](#)). Causa de esto, reafirma que según el [apéndice 10](#), las variables alfa de Jensen, la PE ratio y el sector conforman el podio de parámetros más importantes para este perfil.

En el cómputo global, el desempeño de los modelos es satisfactorio en la precisión y en la especificidad y en el AUC, pero desfavorable mayoritariamente (quitando el modelo elegido) en la sensibilidad y en el estadístico kappa. Por ello, la capacidad discriminativa de todos los modelos es generalmente es aceptable ([apéndice 15](#)).

Con la información que proporciona la matriz de confusión del *rpart* optimizado ([apéndice 14](#)), este es capaz de no errar en ninguna identificación de la clase positiva, por lo que no se escapa ninguna acción a la que incluir, hecho altamente positivo. Además, el aspecto más atractivo de este modelo es el estadístico Kappa frente al resto de modelos, ya que más de tres cuartos de las predicciones realizadas por el

modelo son independientes del azar, por lo que no es descabellado afirmar que el modelo puede estar captando efectivamente patrones relevantes aplicables en datos no vistos previamente para este perfil en concreto.




Ilustración 15: matriz de confusión *rpart* optimizado neutral (elaboración propia)

#### **5.4 Integración e interpretación general del test set**

Complementario al estadístico Kappa, los *test* de *McNemar* y el  $\text{Acc} > \text{NIR}$  (*Accuracy vs. No Information Rate*) sirven como herramientas para evaluar la significatividad de los modelo. El primero mide si existe sesgo en los errores hacia una de las dos clases que recoge el modelo, mientras que el segundo se centra en saber si la *accuracy* del modelo es mejor frente al azar de pronosticar siempre sobre la clase mayoritaria.

El *test* de *McNemar* ha sido  $p > 0.05$  en todos los modelos, lo que confirma que los errores están balanceados estadísticamente, sin sesgo hacia falsos positivos o negativos. El *p-value* en  $\text{Acc} > \text{NIR}$  demuestra que el conservador y el neutral ( $p = 0.002$  y  $p = 0.004$ ) han superado por un amplio margen al nivel de significatividad común (0.05), por lo que estos dos tienen una mejora significativa en su precisión en comparación con el azar. Sin embargo, en el tolerante ( $p = 0.11$ ), esto no se puede extrapolar, por lo que existe un cierto margen de mejora en este aspecto.

Estas pruebas, complementadas con el estadístico Kappa, validan que existe un patrón relevante que no es producto de inferencias aleatorias. Esto resalta que para tipos más aversos al riesgo y los híbridos, la capacidad de generalización es más robusta, mientras que en el caso de los perfiles más agresivos, su aplicabilidad podría ser limitada.

Perfil	Modelo	Kappa (κ)	Interpretación Kappa	Valor-p (Acc > NIR)	Interpretación Acc > NIR	Test McNemar (p-value)	Interpretación McNemar
Conservador	RF Optimizado	0.8936	Concordancia sustancial	0.0021	Accuracy significativamente mejor	1.000	Errores balanceados (1 FP, 0 FN)
Tolerante	Árbol Genérico	0.6591	Concordancia moderada	0.1071	Accuracy no significativamente mejor	1.000	Errores balanceados (2 FP, 1 FN)
Neutral	Árbol Optimizado	0.8000	Concordancia sustancial	0.0036	Accuracy significativamente mejor	0.4795	Errores balanceados (2 FP, 0 FN)

**Ilustración 16: Comparación significatividad para modelos escogidos por perfil (elaboración propia)**

Añadido a esto y suplementado con los estadísticos de significatividad, justamente estos modelos son los que mejor responden a las necesidades de cada perfil. Para el conservador, es más importante tener una tasa de falsos positivos baja (especificidad), ya que es mucho más crítico incluir una acción dentro de una cartera que no soportaría tener un aumento injustificado de la incertidumbre. En cuanto al tolerante, sería al revés, porque sería crucial tener una tasa mínima de falsos negativos (sensibilidad), es decir, no admitiría desechar ninguna oportunidad rentable en la que invertir. Por último, un perfil intermedio estaría más obstinado en conseguir una capacidad discriminativa general máxima para minimizar ambas tasas cuanto sea posible (AUC). Debido a todo esto, la coherencia demostrada refuerza la validez de los modelos elegidos.

Con estas nociones de la valoración que se puede hacer sobre la robustez de cada modelo para cada perfil, luego en el conservador, la calificación crediticia se consolida como la variable más influyente y es altamente estable. En el caso del perfil neutral, la variable que más destaca por su capacidad discriminativa es el alfa de Jensen, también con una firmeza elevada. Por último, en el perfil tolerante, tanto la rentabilidad acumulada como la calificación crediticia aparecen como las variables más relevantes, aunque con una estabilidad moderada, lo que indica una mayor sensibilidad a los cambios que se pueden producir en el contexto financiero.

## **5.5 Limitaciones de los resultados**

Pese a que los resultados encontrados pueden llegar a ser generalizados, estables y representativos, hay unas claras limitaciones que merece la pena mencionar para mantener la transparencia en el trabajo.

En primer lugar, es necesario subrayar que los patrones descubiertos por los modelos de clasificación no deben ser interpretados como relaciones causales, sino como

asociaciones observadas en los datos disponibles. Esto significa que las reglas de decisión encontradas no son excluyentes ni definitivas, y que su validez se limita a las condiciones particulares de este estudio. Por tanto, los hallazgos deben ser considerados exploratorios, y deberían complementarse con investigaciones posteriores más amplias para confirmar su solidez.

Evidentemente, una es el tamaño de *train* y *test set*, lo que genera un contratiempo importante a la hora de la construcción y obtención de resultados ya que con conjuntos de datos tan pequeños, los modelos de clasificaciones sufren en su generación y predicciones.

Por otro lado, la simplificación de los perfiles de riesgo es una visión claramente reduccionista, ya que para una dimensión tan profunda, considerar solo tres tipos es una forma de facilitar y explorar esta perspectiva, pese a que es algo ampliamente complejo y con diversos tipos existentes.

Finalmente, la falta de inclusión de variables macroeconómicas pierde la oportunidad de analizar otras variables contextuales que se podrían relacionar directamente con el sector al que pertenece cada empresa y el efecto que tienen. Agregado a esto, la ventana temporal escogida puede no capturar ciclos económicos completos y puede no ser representativo del escenario histórico de los negocios componentes del principal índice bursátil español.

## **6. CONCLUSIONES**

El presente trabajo definió al principio como objetivo principal evaluar la efectividad de los árboles de decisión para clasificar acciones del IBEX 35 en función de una serie de diversas variables financieras y perfiles de riesgo diferenciados. Los resultados obtenidos demuestran que, mediante la aplicación de modelos como *rpart* y *randomForest*, tanto en su forma predeterminada como en su forma optimizada, es posible identificar reglas de clasificación que asignan de manera diferenciada las variables más relevantes para cada perfil.

Específicamente, para el tipo conservador lo más importante será el *rating* crediticio para sus decisiones (minimización del riesgo), para el neutro el alfa de Jensen (superar en rentabilidad al mercado) y para el tolerante una combinación del *rating* crediticio y de la rentabilidad acumulada (maximizar el retorno pero sin

sobreexposición a la volatilidad). De esta forma se confirma de manera global, la consecución del objetivo principal a través de los árboles de clasificación para la resolución de la toma de decisiones en el ambiente financiero.

Estos descubrimientos para este contexto van en línea con la teoría financiera para el perfil conservador (Yehan Wang 2024 y Klokholm & Thomsen 2025) y para el neutral (Máximo Camacho 2021), mientras que para el tolerante, aunque no se desvía del todo, resalta el hecho de tener en cuenta también la solvencia crediticia de la entidad para la toma de decisión.

Para poder apoyar estas afirmaciones, se ha hecho hincapié en la evaluación de la invariabilidad de los modelos escogidos. La fijación de parámetros como el *test de McNemar*, el *p-value* asociado a "*Accuracy > NIR*" y el índice de Kappa, aportan las evidencias empíricas necesarias para la confirmación de la significatividad estadística encontrada en estos modelos, es decir, la identificación de patrones relevantes superando al rendimiento que cabría esperar por azar.

Secundariamente, también ha sido posible responder a la necesidad de incrementar la fluidez de inspección sobre información financiera, mediante el flujo de trabajo descrito en el cuerpo central del proyecto con la herramienta de *Rstudio*, permitiendo el tratamiento y análisis de una gran cantidad de datos de forma ágil. Seguidamente, se ha conseguido evaluar el desempeño de los modelos para cada perfil de riesgo de un modo exitoso con la ayuda de las matrices de confusión y las métricas de probabilidades (AUC y curva ROC).

Las repercusiones de los hallazgos obtenidos pueden tener implicaciones en el ámbito práctico al servir como orientación en la selección de activos según el perfil de riesgo del inversionista, como una aproximación inicial. En cuanto a la perspectiva teórica, la integración de variables de riesgo, rentabilidad, rentabilidad ajustada al riesgo y valoración patentan la contribución a la captación de comportamientos y tendencias relevantes dentro del mercado financiero estudiado.

No obstante, cabe mencionar que es fundamental subrayar que los hallazgos deben considerarse meramente exploratorios. Las asociaciones detectadas en los datos no implican relaciones causales, sino que solamente se recalca que sirven como punto de partida para futuras investigaciones en el área.

Por ello, como valoración crítica general, se puede decir que el proyecto sienta un precedente prometedor sobre la aplicación de técnicas de *machine learning* como los árboles de decisión para la clasificación de activos financieros, destacando como

puntos fuertes la minuciosa evaluación de los modelos y la diferenciación de reglas de clasificación según el tipo de individuo. Contrariamente, la limitación en la profundidad del análisis se muestra cuando se tiene en cuenta la limitación inherente al tamaño y balance de la muestra, la posible pérdida de información temporal al transformar datos, la falta de variables macroeconómicas y la simplificación a tres perfiles de riesgo, lo que reduce la agudeza del análisis en contextos (habitualmente) más complejos y únicos.

Para superar los obstáculos identificados se propone ampliar lo máximo posible el horizonte temporal y el número de empresas con las que trabajar, para poder aumentar la información a manejar disponible, causando una mayor estabilidad en los resultados generados. Asimismo, integrar variables macroeconómicas o que analicen el sentimiento del mercado sería interesante para añadir más dimensiones al análisis realizado y el significativo posible efecto que pueden llegar a aportar. Finalmente, apostar por modelos híbridos que combinen datos transversales y temporales, así como aumentar la diversidad de perfiles de riesgo, pueden ser enfoques que también proporcionen un aumento de valor a la investigación.

## **DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL**

En la elaboración del presente Trabajo de Fin de Grado se ha recurrido al uso de herramientas de inteligencia artificial con el fin de apoyar distintas fases del proceso académico. Estas herramientas se emplearon para la formulación de posibles temas iniciales, con la búsqueda de información bibliográfica relevante, la organización de puntos a tratar en cada sección, así como evaluaciones y sugerencias preliminares sobre el contenido creado.

Se ha usado *Deepseek* (versión 3.2.1) principalmente en ser un asistente empleado en tareas de apoyo en la estructuración del contenido, junto con revisiones y evaluaciones iniciales y *ChatGPT* (modelo *GPT-4*, *OpenAI*, versión junio 2024): fue usada para la generación del tema del proyecto y para la localización de artículos científicos y técnicos, así como para la gestión de referencias académicas.

El uso de estas herramientas tuvo como objetivo principal optimizar el proceso de redacción y análisis del TFG, facilitando la recopilación de información, la organización de contenidos y la generación de visualizaciones. Su alcance se limitó al apoyo en el diseño metodológico, la sugerencia de buenas prácticas en la aplicación de modelos de clasificación, así como en tareas puntuales de edición lingüística.

El impacto de la inteligencia artificial en el contenido del trabajo se ha manifestado en una mejora en la estructuración lógica de las secciones, una mayor claridad expositiva y una integración más coherente de las evidencias empíricas con los fundamentos teóricos.

La integridad académica y la originalidad del trabajo se han preservado mediante diversas medidas. Por un lado, se han contrastado todas las referencias propuestas con fuentes académicas originales y confiables. Por otro, siempre se ha mantenido la toma de decisiones metodológicas y analíticas basada en criterios científicos sólidos, siendo la inteligencia artificial un recurso complementario y no sustitutivo del razonamiento académico.



## **REFERENCIAS**

1. Goldin, I. (2017). *La innovación financiera: ¿Demasiado de algo bueno?* FMI. <https://www.imf.org/external/pubs/ft/fandd/spa/2017/09/pdf/goldin.pdf>
2. Banco Mundial. (s.f.). *La importancia de la tecnología financiera, el uso de las cuentas y la innovación para lograr la inclusión financiera*. Blogs del Banco Mundial. <https://blogs.worldbank.org/es/voices/la-importancia-de-la-tecnolog-financiera-el-uso-de-las-cuentas-y-la-innovaci-n-para-lograr-la>
3. ING. (s.f.). *Comparación entre ETF, acciones y fondos de inversión*. En Naranja. <https://www.ing.es/ennaranja/invertir-dinero/bolsa-y-mercados/comparacion-etf-acciones-fondos-de-inversion>
4. Banco Santander. (s.f.). *¿Qué son los mercados financieros?* Guía para invertir en bolsa. <https://www.bancosantander.es/particulares/ahorro-inversion/bolsa-inversion/guia-invertir-bolsa/que-son-mercados-financieros>
5. RTVE. (2025, 2<sup>4</sup> de febrero). *Alcanzar bienestar financiero: salud financiera, economía y consejos*. Recuperado el 5 de marzo de 2025, de <https://www.rtve.es/noticias/20250224/alcanzar-bienestar-financiero-salud-financiera-economia-consejos/16463317.shtml>
6. IBM. (n.d.). *Decision trees: Understanding decision tree algorithms and their applications*. Retrieved 5 March 2025, from <https://www.ibm.com/think/topics/decision-trees>
7. Wang,Y. (2025). *A comparative study of stock selection models based on decision tree algorithms*. ResearchGate. Retrieved 5 March 2025, from [https://www.researchgate.net/publication/380752161\\_A\\_Comparative\\_Study\\_of\\_Stock\\_Selection\\_Models\\_Based\\_on\\_Decision\\_Tree\\_Algorithms](https://www.researchgate.net/publication/380752161_A_Comparative_Study_of_Stock_Selection_Models_Based_on_Decision_Tree_Algorithms)
8. Chris Langgaard Klokholm, Rasmus Kongstad Thomsen (2025). *Advanced portfolio optimization using machine learning*. Copenhagen Business School. Retrieved 5 March 2025, from [https://research-api.cbs.dk/ws/portalfiles/portal/108039894/1801494\\_Advanced\\_Portfolio\\_Optimization\\_Using\\_Machine\\_Learning.pdf](https://research-api.cbs.dk/ws/portalfiles/portal/108039894/1801494_Advanced_Portfolio_Optimization_Using_Machine_Learning.pdf)

9. UNIR.net. (s.f.). Árboles de decisión. UNIR Revista. Recuperado el 9 de marzo de 2025, de <https://www.unir.net/revista/ingenieria/arboles-de-decision/>
10. Funcas. (s.f.). *Nuevos métodos de predicción económica con datos masivos\_3.pdf*. Funcas. Recuperado el 9 de marzo de 2025, de [https://www.funcas.es/wp-content/uploads/2021/05/Nuevos-m%C3%A9todos-de-predicci%C3%B3n-econ%C3%B3mica-con-datos-masivos\\_3.pdf](https://www.funcas.es/wp-content/uploads/2021/05/Nuevos-m%C3%A9todos-de-predicci%C3%B3n-econ%C3%B3mica-con-datos-masivos_3.pdf)
11. IBM. (s.f.). Árboles de decisión. IBM Think. Recuperado el 9 de marzo de 2025, de <https://www.ibm.com/es-es/think/topics/decision-trees>
12. López-García, J. (2014). Aplicación de árboles de decisión en la predicción del éxito académico universitario. RIUNET UPV. Recuperado el 9 de marzo de 2025, de <https://riunet.upv.es/handle/10251/45666>
13. Estrategias de Inversión. (2023, 16 de octubre). *20 variables que tener en cuenta antes de comprar una acción*. Recuperado el 12 de marzo de 2025, de <https://www.estrategiasdeinversion.com/analisis/bolsa-y-mercados/el-experto-opina/20-variables-que-tener-en-cuenta-antes-de-comprar-n-793919>
14. Santander. (s.f.). *¿Qué son los índices bursátiles y para qué sirven?* Recuperado el 12 de marzo de 2025, de <https://www.santander.com/es/stories/que-son-los-indices-bursatiles-y-para-que-sirven>
15. Santander Asset Management. (s.f.). *Todo lo que necesitas saber sobre el IBEX 35*. Recuperado el 12 de marzo de 2025, de <https://www.santanderassetmanagement.es/todo-lo-que-necesitas-saber-sobre-el-ibex-35/>
16. Cruz Fernández, L. (2024, 23 de diciembre). *IBEX 35: Empresas y composición*. MyNewTrading. Recuperado el 12 de marzo de 2025, de <https://www.mynewtrading.com/ibex35-empresas-composicion/>
17. Claves Financieras. (s.f.). Análisis de las empresas del IBEX 35. Recuperado el 13 de marzo de 2025, de <https://clavesfinancieras.com/analisis-de-las-empresas-del-ibex-35>

18. Code Labs Academy. (2023, September 20). \*The Bias-Variance Trade-Off in Machine Learning\* [Título traducido al español]. Retrieved March 13, 2025, from <https://codelabsacademy.com/es/blog/the-bias-variance-trade-off-in-machine-learning>
19. Bolsas y Mercados Españoles. (s.f.). Grifols Clase A (ES0171996087). Recuperado el 13 de marzo de 2025, de <https://www.bolsasymercados.es/bme-exchange/es/Mercados-y-Cotizaciones/Acciones/Mercado-Continuo/Ficha/Grifols-Clase-A-ES0171996087>
20. La volatilidad: ¿Cómo se calcula? (s.f.). En *Gestión Pasiva*. Recuperado el 14 de marzo de 2025, de <https://www.gestionpasiva.com/la-volatilidad-como-se-calcula/>
21. Guía para invertir en bolsa: Rentabilidad de las inversiones. (s.f.). En *Banco Santander*. Recuperado el 14 de marzo de 2025, de <https://www.bancosantander.es/particulares/ahorro-inversion/bolsa-inversion/guia-invertir-bolsa/rentabilidad-inversiones>
22. Alpha o Alfa de Jensen. (s.f.). En *Estrategias de Inversión*. Recuperado el 14 de marzo de 2025, de <https://www.estrategiasdeinversion.com/herramientas/diccionario/mercados/alp-ha-o-alfa-de-jensen-t-1590>
23. Ratio de Sharpe. (s.f.). En *Bankinter*. Recuperado el 14 de marzo de 2025, de <https://www.bankinter.com/banca/diccionario-economico/ratio-de-sharpe#letra-A>
24. Precio de cierre. (s.f.). En *Rankia*. Recuperado el 14 de marzo de 2025, de <https://www.rankia.com/diccionario/bolsa/precio-cierre>
25. quantmod: Marco de modelado financiero cuantitativo. (s.f.). En *quantmod*. Recuperado el 14 de marzo de 2025, de <https://www.quantmod.com/>
26. Bankinter. (s.f.). *Inversión: ¿Qué es el riesgo financiero?* Bankinter. Recuperado el 22 de marzo de 2025, de <https://www.bankinter.com/blog/finanzas-personales/inversion-que-es-riesgo-financiero>

27. UNIR. (s.f.). *Volatilidad financiera*. UNIR Revista. Recuperado el 22 de marzo de 2025, de <https://www.unir.net/revista/empresa/volatilidad-financiera/>
28. Forex.com. (s.f.). *Volatilidad del mercado de valores y beta*. Forex.com. Recuperado el 22 de marzo de 2025, de <https://www.forex.com/es-latam/news-and-analysis/stock-market-volatility-and-beta/>
29. Pictet AM. (2024). *Agencias de rating: su papel en la economía y los mercados financieros*. Pictet AM. Recuperado el 22 de marzo de 2025, de <https://am.pictet.com/pictetparati/guia-de-finanzas/2024/agencias-de-rating-papel-economia-mercados-financieros>
30. Banco Santander. (s.f.). *Rentabilidad de las inversiones*. Banco Santander. Recuperado el 22 de marzo de 2025, de <https://www.bancosantander.es/particulares/ahorro-inversion/bolsa-inversion/guia-invertir-bolsa/rentabilidad-inversiones>
31. Fintai. (s.f.). *¿Qué son los retornos logarítmicos?* Fintai. Recuperado el 22 de marzo de 2025, de <https://www.fintai.es/matematicas-financieras/que-son-los-retornos-logaritmicos/>
32. inbestMe. (s.f.). *Así funciona la rentabilidad acumulada*. inbestMe. Recuperado el 22 de marzo de 2025, de <https://www.inbestme.com/es/es/blog/asi-funciona-rentabilidad-acumulada/>
33. Investopedia. (n.d.). *Compound interest*. Retrieved March 22, 2025, from <https://www.investopedia.com/terms/c/compoundinterest.asp>
34. Economipedia. (s.f.). *Rentabilidad relativa*. Economipedia. Recuperado el 22 de marzo de 2025, de <https://economipedia.com/definiciones/rentabilidad-relativa.html>
35. UNIA. (s.f.). *Métodos de valoración de activos financieros: herramientas clave para tomar decisiones de inversión*. UNIA. Recuperado el 23 de marzo de 2025, de <https://www.unia.es/vida-universitaria/blog/metodos-de-valoracion-de-activos-financieros-herramientas-clave-para-tomar-decisiones-de-inversion>

36. LiteFinance. (s.f.). *Análisis fundamental en el trading*. LiteFinance. Recuperado el 23 de marzo de 2025, de <https://www.litefinance.org/es/blog/for-beginners/analisis-fundamental-en-el-trading/>
37. Estrategias de Inversión. (s.f.). *PER*. Estrategias de Inversión. Recuperado el 24 de marzo de 2025, de <https://www.estrategiasdeinversion.com/herramientas/diccionario/analisis-fundamental/per-t-368>
38. Statistics Easiliy. (s.f.). *¿Qué es la guía completa de interpolación lineal?*. Statistics Easiliy. Recuperado el 24 de marzo de 2025, de <https://es.statisticseasily.com/glosario/%C2%BFQu%C3%A9-es-la-gu%C3%ADa-completa-de-interpolaci%C3%B3n-lineal%3F>
39. CEUPE. (s.f.). *Rentabilidad ajustada al riesgo*. CEUPE. Recuperado el 24 de marzo de 2025, de <https://www.ceupe.com/blog/rentabilidad-ajustada-al-riesgo.html>
40. Raisin. (s.f.). *¿Qué es la tasa libre de riesgo y cómo se calcula?*. Raisin. Recuperado el 24 de marzo de 2025, de <https://www.raisin.es/educacion-financiera/que-es-la-tasa-libre-de-riesgo-y-como-se-calcula/>
41. Bankinter. (s.f.). *Ratio de Sharpe*. Bankinter. Recuperado el 24 de marzo de 2025, de <https://www.bankinter.com/banca/diccionario-economico/ratio-de-sharpe>
42. Estrategias de Inversión. (s.f.). *Alpha o Alfa de Jensen*. Estrategias de Inversión. Recuperado el 24 de marzo de 2025, de <https://www.estrategiasdeinversion.com/herramientas/diccionario/mercados/alpha-o-alfa-de-jensen-t-1590>
43. FasterCapital. (s.f.). *Alfa de Jensen: cómo utilizarlo para medir el rendimiento anormal de su cartera*. Recuperado el 24 de marzo de 2025, de <https://fastercapital.com/es/contenido/Alfa-de-Jensen--como-utilizarlo-para-medir-el-rendimiento-anormal-de-su-cartera.html#Limitaciones-y-cr-ticas-de-Jensens-Alpha>

44. Llinas, H. (s.f.). *R Librerías*. RPubS. Recuperado el 25 de marzo de 2025, de [https://rpubs.com/hllinas/R\\_Librerias](https://rpubs.com/hllinas/R_Librerias)
45. Ryan, J. A., & Ulrich, J. M. (n.d.). *quantmod: Quantitative financial modelling framework*. Retrieved March 25, 2025, from <https://www.quantmod.com/>
46. Wickham, H., François, R., Henry, L., & Müller, K. (n.d.). *dplyr: A grammar of data manipulation*. Retrieved March 25, 2025, from <https://dplyr.tidyverse.org/>
47. Wickham, H., & Girlich, M. (n.d.). *tidyr: Tidy messy data*. Retrieved March 25, 2025, from <https://tidyr.tidyverse.org/>
48. Grolemund, G., & Wickham, H. (n.d.). *lubridate: Make dealing with dates a little easier*. Retrieved March 25, 2025, from <https://lubridate.tidyverse.org/>
49. Dancho, M., & Vaughan, D. (n.d.). *tidyquant: Bringing financial analysis to the tidyverse*. Retrieved March 25, 2025, from <https://business-science.github.io/tidyquant/>
50. Zeileis, A., & Grothendieck, G. (n.d.). *zoo: S3 infrastructure for regular and irregular time series* (Version 1.8-12). Retrieved March 25, 2025, from <https://www.rdocumentation.org/packages/zoo/versions/1.8-12>
51. Warnes, G. R., et al. (s.f.). *gplots: Various R programming tools for plotting data*. Recuperado el 25 de marzo de 2025, de <https://cran.r-project.org/web/packages/gplots/index.html>
52. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
53. Corporate Finance Institute. (n.d.). *Autocorrelation*. Retrieved March 25, 2025, from <https://corporatefinanceinstitute.com/resources/data->

[science/autocorrelation/#:~:text=Autocorrelation%20refers%20to%20the%20degree,also%20known%20as%20serial%20correlation](#)

54. Economipedia. (s.f.). *Dependencia temporal*. Recuperado el 25 de marzo de 2025, de <https://economipedia.com/definiciones/dependencia-temporal.html>
55. KeepCoding. (s.f.). *Árboles de decisión sobre series temporales*. Recuperado el 26 de marzo de 2025, de <https://keepcoding.io/blog/arboles-de-decision-sobre-series-temporales/>
56. Khan Academy. (s.f.). *Repaso de media, mediana y moda*. Recuperado el 26 de marzo de 2025, de <https://es.khanacademy.org/math/statistics-probability/summarizing-quantitative-data/mean-median-basics/a/mean-median-and-mode-review>
57. Wickham, H. & Golemund, G. (s.f.). *Análisis exploratorio de datos (EDA). R para Ciencia de Datos*. Recuperado el 28 de marzo de 2025, de <https://es.r4ds.hadley.nz/07-eda.html>
58. QuestionPro. (s.f.). *Matriz de correlación: Qué es y cómo interpretarla*. Recuperado el 28 de marzo de 2025, de <https://www.questionpro.com/blog/es/matriz-de-correlacion/>
59. Cochrane. (s.f.). *Correlación no implica causalidad*. Recuperado el 28 de marzo de 2025, de <https://es.cochrane.org/es/divulgacion/pensamiento-critico/correlacion-no-implica-causalidad>
60. DataTab. (2023). *Correlación estadística: Análisis y ejemplos*. Recuperado el 28 de marzo de 2025, de <https://datatab.es/tutorial/correlation>
61. Máxima Formación. (s.f.). *¿Qué es la multicolinealidad y por qué es un problema?* Recuperado el 28 de marzo de 2025, de <https://www.maximaformacion.es/blog-ciencia-datos/que-es-la-multicolinealidad-y-por-que-es-un-problema/>
62. DataCamp. (s.f.). *Factor de Inflación de la Varianza (VIF): Tutorial*. Recuperado el 28 de marzo de 2025, de <https://www.datacamp.com/es/tutorial/variance-inflation-factor>

63. García-Vera, A. B., & Sanz-Valero, J. (2020). Pruebas de bondad de ajuste en la investigación educativa. *Revista Docentes20*, 14(32), 1-13. Recuperado el 2 de abril de 2025, de <https://ojs.docentes20.com/index.php/revista-docentes20/article/download/554/1420/7496>
64. Dey, R. (2020, August 26). *Normal distribution and its significance*. Medium. Retrieved April 2, 2025, from <https://medium.com/@roshmitadey/normal-distribution-and-its-significance-10fea108588c>
65. StudySmarter ES. (s.f.). Métodos no paramétricos. Recuperado el 2 de abril de 2025, de <https://www.studysmarter.es/resumenes/matematicas/estadisticas/metodos-no-parametricos/>
66. IBM. (s.f.). Tipos de gráficos Q-Q. *IBM Documentation*. Recuperado el 2 de abril de 2025, de <https://www.ibm.com/docs/es/spss-statistics/beta?topic=types-q-q-plots>
67. QuestionPro. (s.f.). Prueba de Kruskal-Wallis. Recuperado el 2 de abril de 2025, de <https://www.questionpro.com/blog/es/prueba-de-kruskal-wallis/>
68. QuestionPro. (s.f.). ANOVA. Recuperado el 2 de abril de 2025, de <https://www.questionpro.com/blog/es/anova/>
69. CNMV. (s.f.). ¿Qué es su perfil inversor? *CNMV*. Recuperado el 29 de marzo de 2025, de [https://www.cnmv.es/TutorialesInversores/DecisionesInversion/02\\_CNMV\\_accesible/0301.htm](https://www.cnmv.es/TutorialesInversores/DecisionesInversion/02_CNMV_accesible/0301.htm)
71. El Economista. (2019, 29 de mayo). Qué volatilidad debe asumir cada perfil inversor. *El Economista*. Recuperado el 29 de marzo de 2025, de <https://www.eleconomista.es/mercados-cotizaciones/noticias/9854274/05/19/Que-volatilidad-debe-asumir-cada-perfil-inversor.html>
72. Bankinter. (s.f.). Inversión y riesgo financiero: ¿qué es VAR, VIX y Beta? *Bankinter*. Recuperado el 29 de marzo de 2025, de <https://www.bankinter.com/blog/finanzas-personales/inversion-riesgo-financiero-que-es-var-vix-beta>



73. Abanfin. (s.f.). Ratings emisiones de renta fija. *Abanfin*. Recuperado el 29 de marzo de 2025, de <https://www.abanfin.com/?tit=ratings-emisiones-de-renta-fija&name=Manuales&fid=gh00011>
74. Infante, A. (s.f.). Mejores inversiones según el riesgo. *Finect*. Recuperado el 29 de marzo de 2025, de <https://www.finect.com/usuario/AsunInfante/articulos/mejores-inversiones-riesgo>
75. El Economista. (2023, 23 de junio). Si su cartera de inversión es arriesgada, debería estar ganando un 6%. *El Economista*. Recuperado el 29 de marzo de 2025, de <https://www.eleconomista.es/mercados-cotizaciones/noticias/12345891/06/23/si-su-cartera-de-inversion-es-arriesgada-deberia-estar-ganando-un-6.html>
76. ING. (s.f.). ¿Qué es el PER? *ING*. Recuperado el 29 de marzo de 2025, de <https://www.ing.es/enarranja/invertir-dinero/bolsa-y-mercados/que-es-el-per>
77. Banco Santander. (s.f.). Price Earning Ratio (PER). *Banco Santander*. Recuperado el 29 de marzo de 2025, de <https://www.bancosantander.es/glosario/price-earning-ratio-per>
78. Fondos Indexados. (s.f.). Ratio de Sharpe. *Fondos Indexados*. Recuperado el 29 de marzo de 2025, de <https://www.fondosindexados.net/ratio-sharpe/>
79. Barón, S. (s.f.). Alfa y Beta en un fondo: ¿qué son? *Finect*. Recuperado el 29 de marzo de 2025, de <https://www.finect.com/usuario/santiagobaron/articulos/alfa-beta-fondo-que-son>
80. Sanderson, S. P. (2023, September 29). *Interpreting the decision tree*. Steve on Data. Retrieved March 29, 2025, from <https://www.spsanderson.com/steveondata/posts/2023-09-29/index.html>
81. Kdagiit. (n.d.). *Bagging and random forests: Reducing bias and variance using randomness*. Medium. Retrieved March 29, 2025, from <https://kdagiit.medium.com/bagging-and-random-forests-reducing-bias-and-variance-using-randomness-8d516214fe7f>

82. Lejarza, M. (s.f.). Árboles de decisión. *Universidad de Valencia*. Recuperado el 29 de marzo de 2025, de <https://www.uv.es/mlejarza/actuariales/tam/arbolesdecision.pdf>
83. (s.f.). Árboles de Decisión Parte I. *Bookdown*. Recuperado el 29 de marzo de 2025, de <https://bookdown.org/content/2031/arboles-de-decision-parte-i.html>
84. Vilchez, F. (s.f.). Árboles. *Aprendizaje supervisado en R*. Recuperado el 29 de marzo de 2025, de <https://fervilber.github.io/Aprendizaje-supervisado-en-R/arboles.html>
85. Lukito, J. (s.f.). *Random Forest*. bookdown.org. Recuperado el 10 de abril de 2025, de [https://bookdown.org/josephine\\_lukito/bookdown-demo/random-forest.html](https://bookdown.org/josephine_lukito/bookdown-demo/random-forest.html)
86. Google Developers. (s.f.). Dividir conjuntos de datos. *Machine Learning Crash Course*. Recuperado el 31 de marzo de 2025, de <https://developers.google.com/machine-learning/crash-course/overfitting/dividing-datasets?hl=es-419>
87. DataCamp. (s.f.). Validación cruzada k-fold. Recuperado el 31 de marzo de 2025, de <https://www.datacamp.com/es/tutorial/k-fold-cross-validation>
88. Barrios, J. (2022, 18 de agosto). La matriz de confusión y sus métricas. *JuanBarrios.com*. Recuperado el 31 de marzo de 2025, de <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>
89. DataCamp. (s.f.). AUC. Recuperado el 31 de marzo de 2025, de <https://www.datacamp.com/es/tutorial/auc>
90. QuestionPro. (s.f.). Kappa de Cohen. Recuperado el 31 de marzo de 2025, de <https://www.questionpro.com/blog/es/kappa-de-cohen/>
91. IBM. (s.f.). *Modelo ARIMA*. IBM Think Topics. Recuperado el 2 de abril de 2025, de <https://www.ibm.com/es-es/think/topics/arima-model>
92. Advisor's Edge. (n.d.). *Energy and commodities listed as value trap hot beds*. advisor.ca. Retrieved April 14, 2025, from

<https://www.advisor.ca/investments/market-insights/energy-and-commodities-listed-as-value-trap-hot-beds>

93. Finanzas.com. (s.f.). *Ibex 35: Los que mejor exprimen el rebote no son bancos*.  
finanzas.com. Recuperado el 14 de abril de 2025, de  
<https://www.finanzas.com/ibex-35/ibex-35-mejor-exprimen-el-rebote-no-son-bancos.html>

## **Índice de anexos**

Anexo 1: Clasificación del IBEX 35 sobre la ponderación por empresas.....	61
Anexo 2: Sistema de puntuación de las tres agencias de rating principales a l/p.....	62
Anexo 3: Escala de fuerzas de correlación .....	63
Anexo 4: Resumen métricas de evaluación de una matriz de confusión .....	64

**Anexo 1: Clasificación del IBEX 35 sobre la ponderación por empresas  
(actualizado a 2024 diciembre)**

CLASIFICACIÓN	EMPRESAS DEL IBEX 35
1	INDITEX
2	IBERDROLA, S.A.
3	BANCO SANTANDER, S.A.
4	BBVA
5	CAIXABANK, S.A.
6	AMADEUS IT GROUP, S.A.
7	FERROVIAL SE
8	CELLNEX TELECOM, S.A.
9	TELEFÓNICA, S.A.
10	AENA S.M.E., S.A.
11	REPSOL S.A.
12	ACS, ACTIVIDADES DE CONSTRUCCIÓN Y SERVICIOS, S.A.
13	BANCO DE SABADELL, S.A.
14	INTERNATIONAL CONSOLIDATED AIRLINES GROUP, S.A.
15	REDEIA CORPORACION S.A.
16	ENDESA, S.A.
17	BANKINTER, S.A.
18	ACCIONA, S.A.
19	MERLIN PROPERTIES SOCIMI, S.A.
20	NATURGY ENERGY GROUP, S.A.
21	MAPFRE S.A.
22	ARCELORMITTAL
23	GRIFOLS, S.A.
24	INDRA SISTEMAS, S.A.

Nota: Reproducción de "IBEX 35: Empresas y composición", por L. Cruz Fernández, 2024, 23 de diciembre, *MyNewTrading*. Recuperado el 9 de marzo de 2025, de <https://www.mynewtrading.com/ibex35-empresas-composicion/>

## Anexo 2: Sistema de puntuación de las tres agencias de rating principales a largo plazo

Largo Plazo			
	MOODY'S	STANDAR & POORS	FITCH IBCA
Grado de inversión	AAA	AAA	AAA
	Aa1	AA+	AA+
	Aa2	AA	AA
	Aa3	AA-	AA-
	A1	A+	A+
	A2	A	A
	A3	A-	A-
	Baa1	BBB+	BBB+
	Baa2	BBB	BBB
	Baa3	BBB-	BBB-
Bonos basura ó "High Yield"	Ba1	BB+	BB+
	Ba2	BB	BB
	Ba3	BB-	BB-
	B3	B+	B+
	B2	B	B
	B1	B-	B-
	Caa	CCC	CCC
	Ca	CC	CC
	C	C	C
	C	D	D


Nota: Reproducción de Pictet Asset Management. (2024). *Agencias de rating: Su papel en la economía y los mercados financieros*. Recuperado el 22 de marzo de 2025, de <https://am.pictet.com/pictetparati/guia-de-finanzas/2024/agencias-de-rating-papel-economia-mercados-financieros>

### Anexo 3: Escala de fuerzas de correlación

Valor r	Fuerza de la correlación
$0.0 < 0.1$	no hay correlación
$0.1 < 0.3$	poca correlación
$0.3 < 0.5$	correlación media
$0.5 < 0.7$	correlación alta
$0.7 < 1$	correlación muy alta

*Nota.* Reproducción "Correlation analysis in statistical studies" de *DataTab*, 2023.  
Recuperado el 28 de marzo de 2025, de <https://datatab.es/tutorial/correlation>

#### Anexo 4: Resumen métricas de evaluación de una matriz de confusión



Nota: Reproducción de "La matriz de confusión y sus métricas", por J. Barrios, 2022, 18 de agosto, *JuanBarrios.com*. Recuperado el 31 de marzo de 2025, de <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>



## **Índice de apéndices**

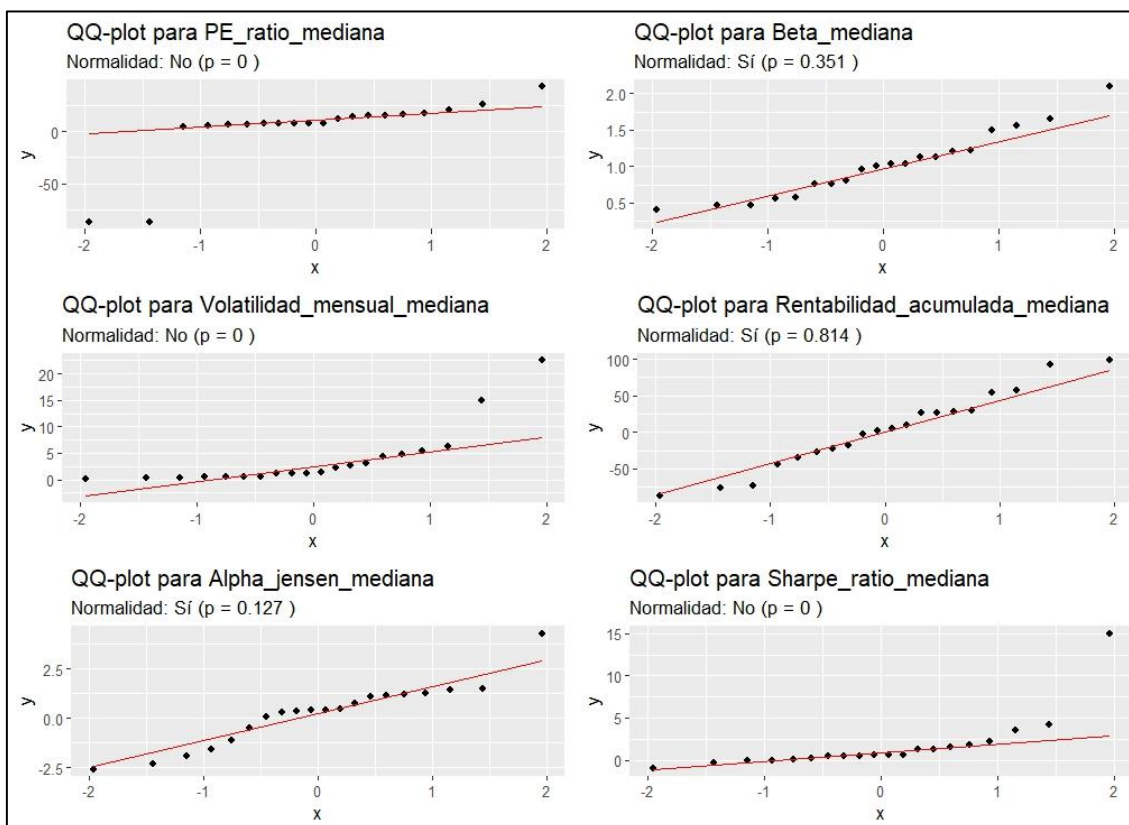
Apéndice 1: Resultados comprobación normalidad con prueba <i>Shapiro-Wilk</i> .....	66
Apéndice 2: Gráficos QQ variables numéricas.....	67
Apéndice 3: Tabla comparación entre sectores .....	68
Apéndice 4: Tabla resumen umbrales para variables.....	69
Apéndice 5: Comparación importancia de variables para el perfil conservador en el entrenamiento modelos genéricos .....	70
Apéndice 6: Comparación importancia de variables para el perfil tolerante en el entrenamiento modelos genéricos .....	71
Apéndice 7: Comparación importancia de variables para el perfil neutral en el entrenamiento modelos genéricos .....	72
Apéndice 8: Comparación importancia de variables para el perfil conservador en el entrenamiento modelos optimizados.....	73
Apéndice 9: Comparación importancia de variables para el perfil tolerante en el entrenamiento modelos optimizados.....	74
Apéndice 10: Comparación importancia de variables para el perfil neutral en el entrenamiento modelos optimizados.....	75
Apéndice 11: Tablas de métricas por modelo para todos los perfiles <i>test set</i> .....	76
Apéndice 12: Matrices de confusión distintos modelos tipo conservador .....	77
Apéndice 13: Matrices de confusión distintos modelos tipo tolerante.....	78
Apéndice 14: Matrices de confusión distintos modelos tipo neutral.....	79
Apéndice 15: Comparación curvas ROC entre modelos y perfiles .....	80

### Apéndice 1: Resultados comprobación normalidad con prueba *Shapiro-Wilk*

Variable	W	p_value	Normalidad
PE_ratio_mediana	0.544	0.000	No
Beta_mediana	0.929	0.145	Sí
Volatilidad_mensual_mediana	0.686	0.000	No
Rentabilidad_acumulada_mediana	0.883	0.020	No
Alpha_jensen_mediana	0.947	0.323	Sí
Sharpe_ratio_mediana	0.779	0.000	No

Nota: elaboración propia

## Apéndice 2: Gráficos QQ variables numéricas



Nota: elaboración propia

### Apéndice 3: Tabla comparación entre sectores

Variable	Test Utilizado	Estadístico ( $\chi^2/F$ )	Grados de Libertad (df)	p-value	Significancia	Conclusión
Volatilidad_mensual_mediana	Kruskal-Wallis	15.554	7	0.02952	*	Diferencias significativas entre sectores
Rentabilidad_acumulada_mediana	Kruskal-Wallis	14.300	7	0.04610	*	Diferencias significativas entre sectores
PE_ratio_mediana	Kruskal-Wallis	12.324	7	0.09041	ns (p > 0.05)	Diferencias no significativas
Beta_mediana	ANOVA	F = 4.654	7, 12	0.00988	**	Diferencias significativas entre sectores
Sharpe_ratio_mediana	Kruskal-Wallis	56.286	7	0.5837	ns (p > 0.05)	Diferencias no significativas
Alpha_jensen_mediana	ANOVA	F = 4.218	7, 12	0.0143	*	Diferencias significativas entre sectores
<b>Leyenda:</b>						
* p < 0.05, ** p < 0.01, ns = no significativo.						


Nota: elaboración propia

## Apéndice 4: Tabla resumen umbrales para variables

Factor	Conservador	Neutral	Agresivo	Justificación
<b>Rentabilidad Acumulada</b>	> 3%	> 4%	> 7%	Para conservadores se requiere una rentabilidad mínima superior al 3% ( <i>benchmark</i> de fondos conservadores). Los neutrales buscan una rentabilidad > 4%, y los agresivos > 7% para reflejar un mayor apetito por el riesgo.
<b>Volatilidad</b>	< 2%	< 7%	< 15%	Los conservadores no toleran volatilidad superior al 2%. Los neutrales aceptan volatilidades de hasta 7%, mientras que los agresivos pueden tolerar hasta 15% en su búsqueda de mayores rendimientos.
<b>Beta</b>	< 1	≈ 1	≤ 2	Los conservadores prefieren acciones con beta < 1 (menos volátiles que el mercado). Los neutrales buscan una exposición moderada (beta ≈ 1), mientras que los agresivos aceptan hasta 2, lo que implica mayor sensibilidad al mercado.
<b>Calificación Crediticia</b>	≥ A- (flexible hasta ≥ BBB+)	≥ BBB	≥ BBB-	Conservadores ahora incluyen ≥ A-, con la opción de excepción hasta BBB+, basado en evidencia empírica que muestra su estabilidad relativa en el IBEX 35. Neutrales aceptan BBB, y agresivos hasta BBB-.
<b>Alfa de Jensen</b>	≥ 0%	-1% a 2%	-2% a 3%	Para conservadores, el alfa debe ser ≥ 0% (rendimiento superior al <i>benchmark</i> ). Neutrales toleran una ligera desviación (-1% a 2%), y agresivos un rango más amplio (-2% a 3%).
<b>PER Ratio</b>	0-10	oct-20	> 20	Conservadores prefieren PER bajos (0-10, empresas consolidadas). Neutrales optan por PER intermedios (10-20), y agresivos por PER > 20 (expectativas de
<b>Ratio Sharpe</b>	≥ 1	0.5 a 1	> 0.5	Conservadores exigen Sharpe ≥ 1 (rentabilidad ajustada al riesgo óptima). Neutrales aceptan entre 0.5 y 1, y agresivos > 0.5.

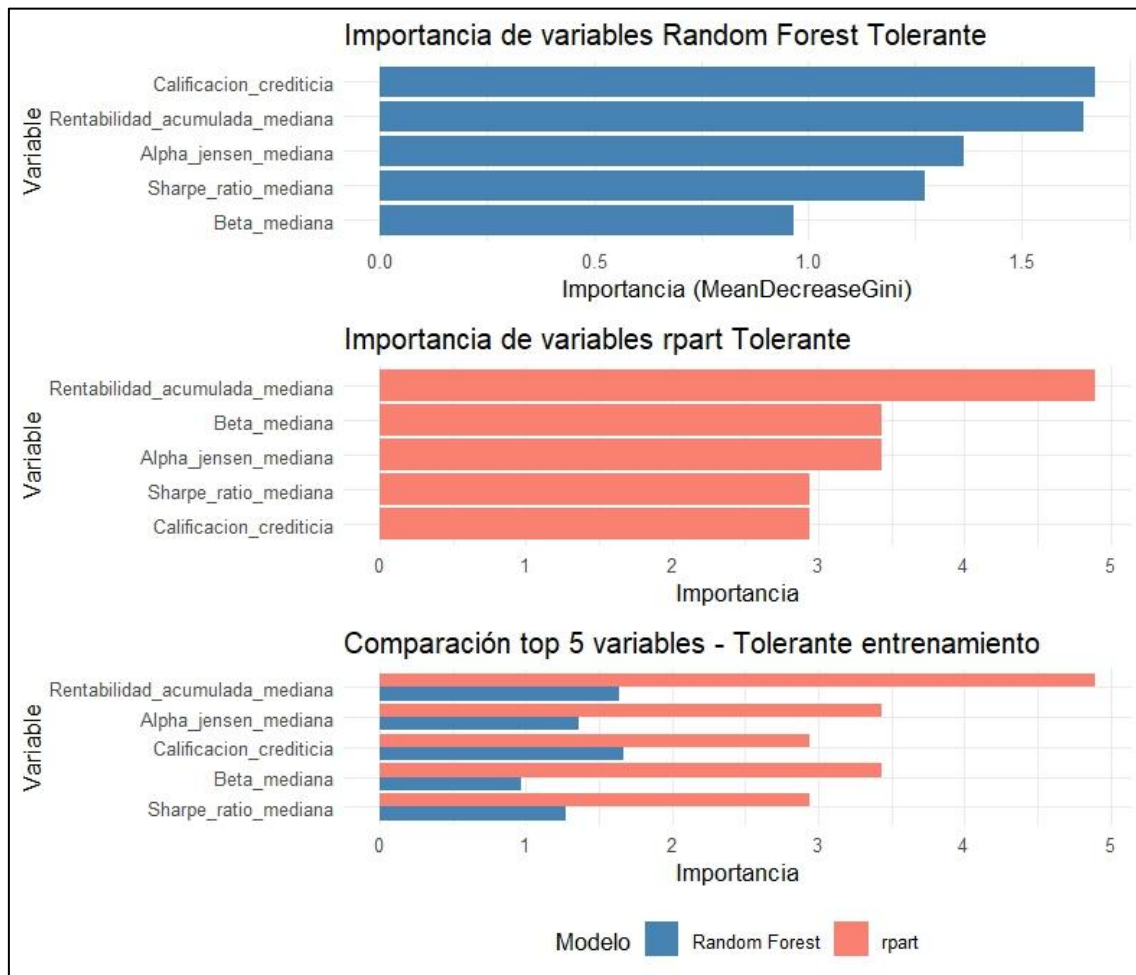
Nota: elaboración propia

## Apéndice 5: Comparación importancia de variables para el perfil conservador en el entrenamiento modelos genéricos



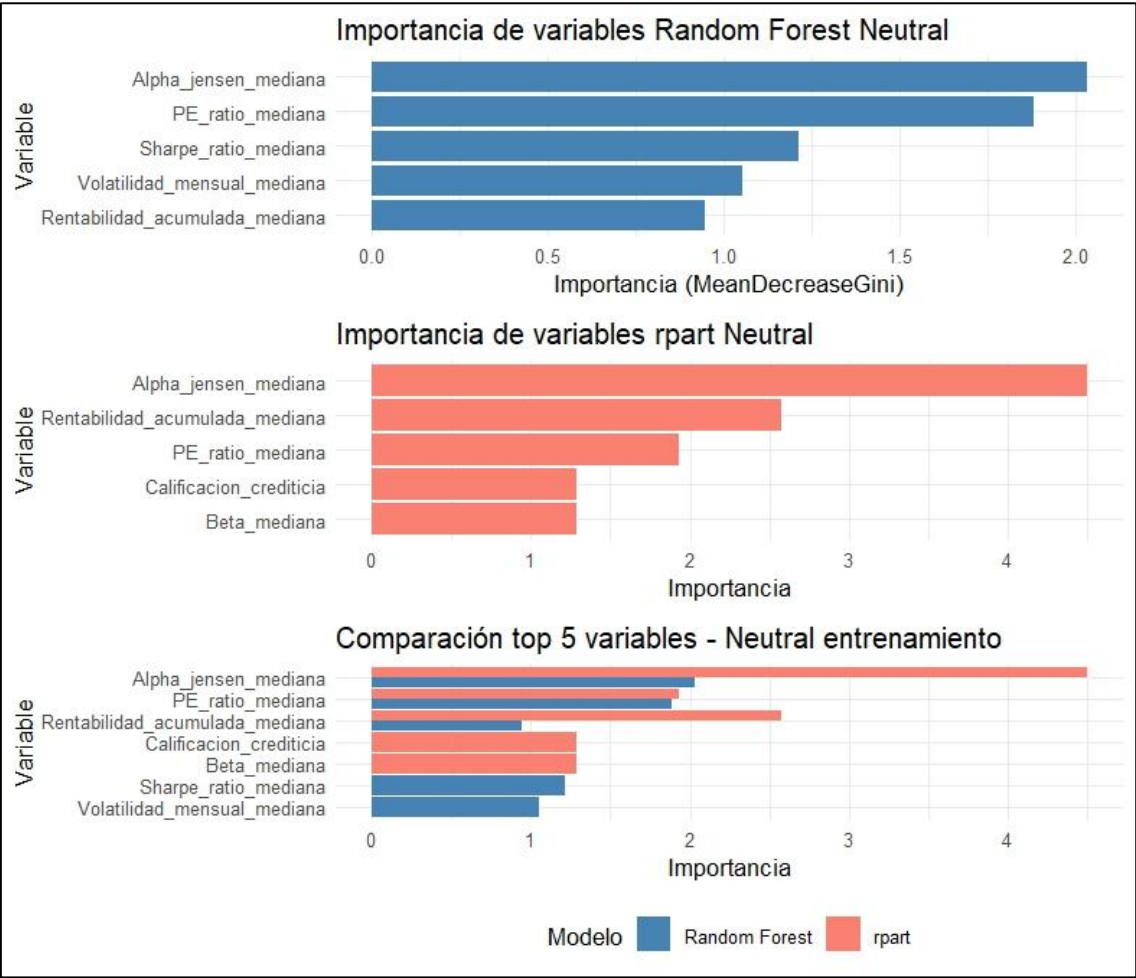
Nota: elaboración propia

## Apéndice 6: Comparación importancia de variables para el perfil tolerante en el entrenamiento modelos genéricos



Nota: elaboración propia

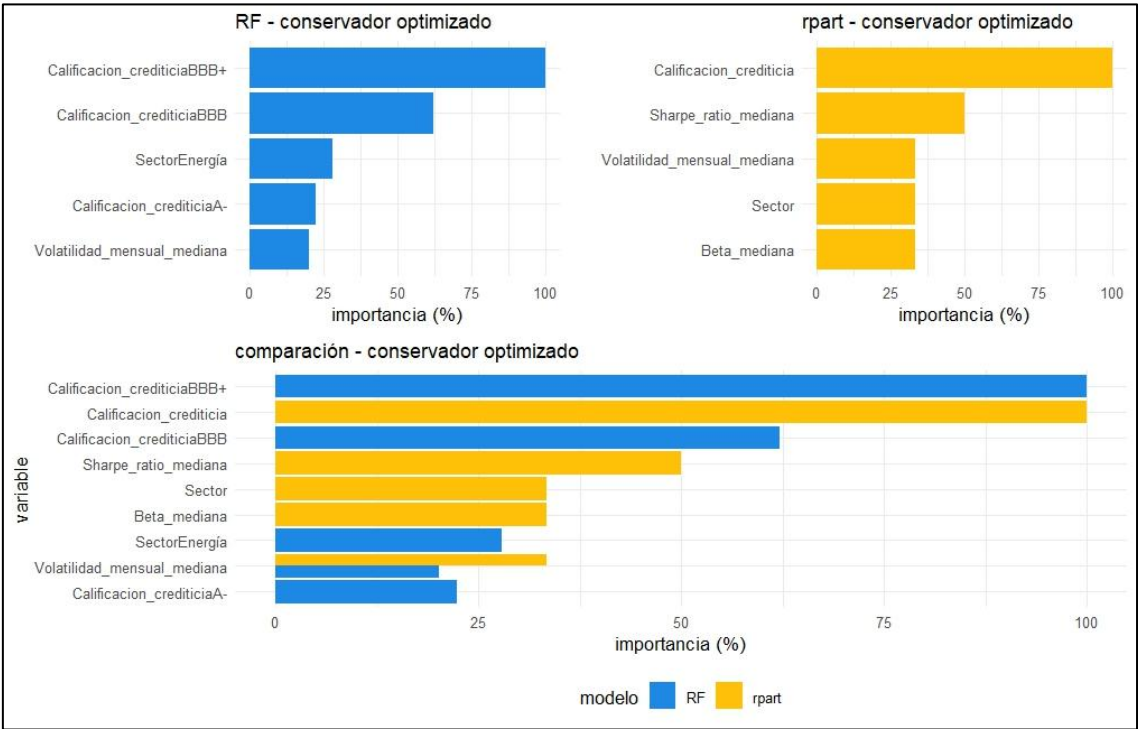
### Apéndice 7: Comparación importancia de variables para el perfil neutral en el entrenamiento modelos genéricos



Nota: elaboración propia

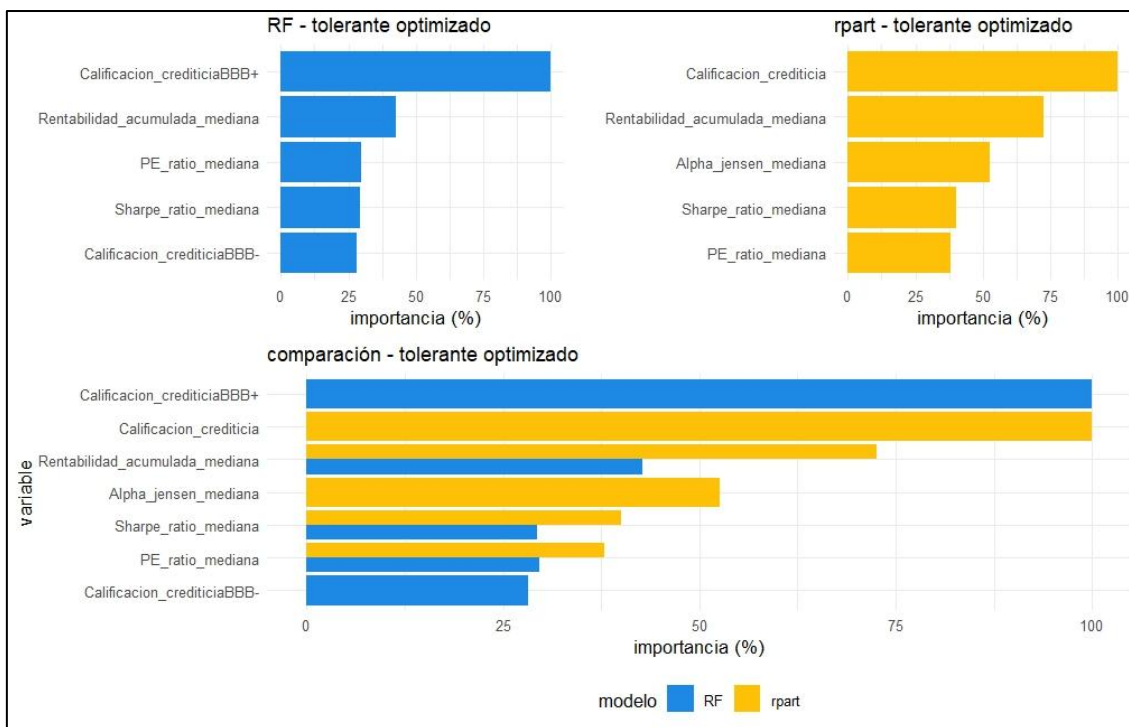


**Apéndice 8: Comparación importancia de variables para el perfil conservador en el entrenamiento modelos optimizados**




Nota: elaboración propia

## Apéndice 9: Comparación importancia de variables para el perfil tolerante en el entrenamiento modelos optimizados



Nota: elaboración propia

## Apéndice 10: Comparación importancia de variables para el perfil neutral en el entrenamiento modelos optimizados



Nota: elaboración propia

## Apéndice 11: Tablas de métricas por modelo para todos los perfiles *test set*

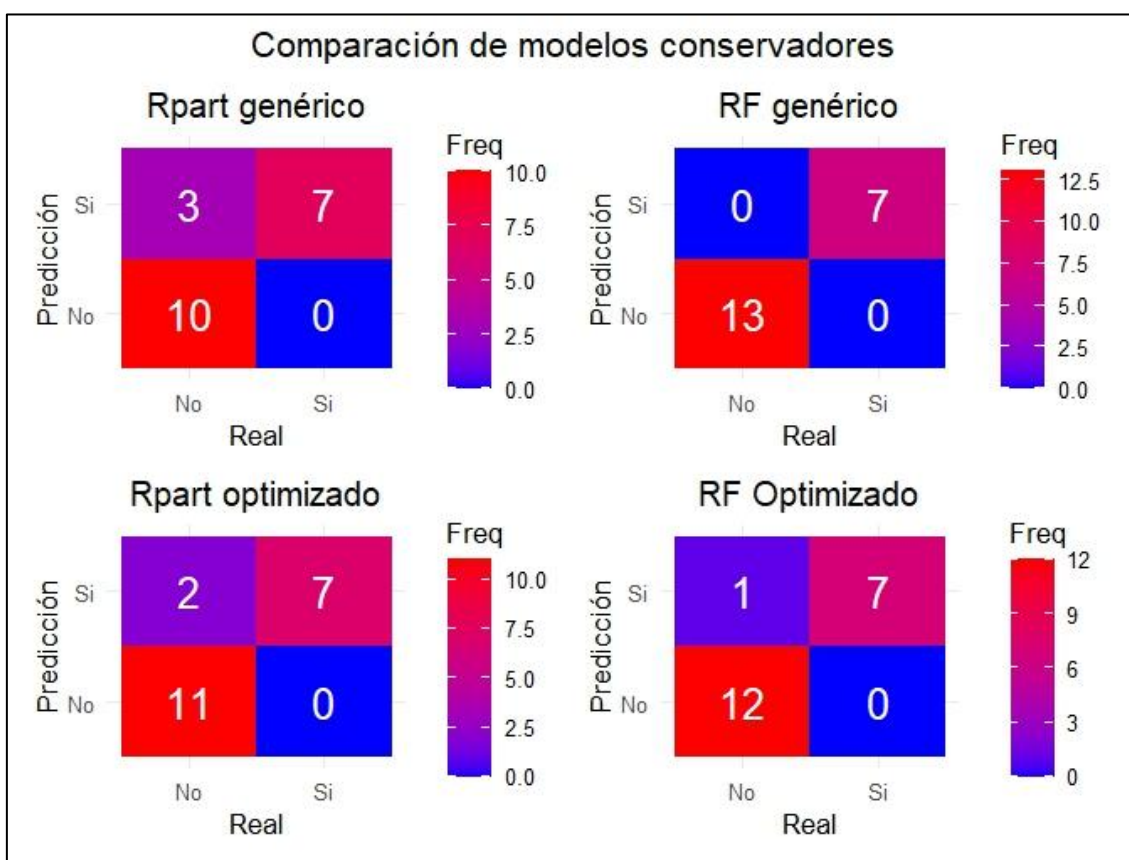
CONSERVADOR ▾	Accuracy ▾	Sensibilidad ▾	Especificidad ▾	Kappa ▾	AUC ▾
RF Optimizado	95%	92.3%	100%	0.89	0.945
RF Genérico	100%	100%	100%	1.00	1.00
Árbol Optimizado	90%	84.6%	100%	0.79	0.923
Árbol Genérico	85%	76.9%	100%	0.70	0.88

TOLERANTE ▾	Accuracy ▾	Kappa ▾	Sensibilidad ▾	Especificidad ▾	AUC ▾
RF Genérico	0.55	0.196	0.833	0.429	0.7
Árbol Genérico	0.85	0.659	0.833	0.857	0.84
RF Optimizado	0.45	-0.058	0.500	0.429	0.429
Árbol Optimizado	0.35	-0.250	0.333	0.357	0.68

NEUTRAL ▾	Accuracy ▾	Sensibilidad ▾	Especificidad ▾	Kappa ▾	AUC ▾
rpart genérico	0.80	0.625	0.917	0.565	0.77
RF genérico	0.85	0.625	1.000	0.667	0.95
rpart optimizado	0.90	1.000	0.833	0.800	0.92
RF optimizado	0.85	0.625	1.000	0.667	0.98


Nota: elaboración propia

## Apéndice 12: Matrices de confusión distintos modelos tipo conservador




Nota: elaboración propia

### Apéndice 13: Matrices de confusión distintos modelos tipo tolerante




Nota: elaboración propia

**Apéndice 14: Matrices de confusión distintos modelos tipo neutral**



Nota: elaboración propia

## Apéndice 15: Comparación curvas ROC entre modelos y perfiles



Nota: elaboración propia